
Dazzle: Una base de datos embebida para agentes LLM on-device

Preprint

Ivan Aliaga
Universidad Ricardo Palma
Lima, Perú
ivan.aliaga@urp.edu.pe

Abril 2026

Abstract

Las aplicaciones móviles que embeben un agente con un modelo de lenguaje hoy necesitan una capa de estado persistente entre las llamadas de inferencia: ventanas de sensores, agregados materializados, conteos aproximados, índices vectoriales sobre contexto reciente. Las bases de datos embebidas disponibles en la plataforma (SQLite, RocksDB, LMDB, ObjectBox) ofrecen entre dos y cuatro primitivas de estructura de datos cada una, así que cada construcción de orden superior (bounded streams, TTL por campo, HyperLogLog, búsqueda vectorial HNSW) termina re-implementada en código de aplicación, sobre esas primitivas, por cada equipo que la necesita.

Presentamos **Dazzle**, un fork de Valkey (la versión Linux Foundation de Redis) cuyo servidor corre *dentro* del proceso de aplicaciones Android e iOS en lugar de como demonio sobre TCP loopback. El fork expone diez primitivas nativas de estructura de datos, incluyendo búsqueda vectorial HNSW, contra ≤ 4 en cualquier competidor embebido que medimos en las mismas plataformas; las expone a través de un SDK móvil tipado en Maven Central, pub.dev, npm y Swift Package Manager.

Caracterizamos el envelope de latencia para doce backends en dos dispositivos físicos (Moto G35 5G, iPhone 12 Pro). El retrieval en estado estable sobre el path de agregados materializados aterriza en 50 μ s en el Moto G35 5G y 7.24 μ s en el iPhone 12 Pro; la búsqueda vectorial HNSW se mantiene en sub-milisegundo a recall ≥ 0.95 a lo largo de la grilla de 9 configuraciones que medimos. A 50 μ s frente a un turno de inferencia LLM on-device de ~ 2.84 s, el costo de retrieval representa el **0.00176 %** de la llamada de inferencia: por debajo del piso de ruido del bucle end-to-end. El eje de decisión para un backend de agente on-device es por tanto la **superficie primitiva y la ergonomía del desarrollador**, no los deltas de microbenchmark. Reportamos los números absolutos por motor en microsegundos de todas formas, porque los mismos motores también sirven cargas no-LLM (analítica, sincronización, indexación) donde los microsegundos sí importan.

Una ablación 2 $\times$ 2 end-to-end sobre 200 queries de Natural Questions en el Moto G35 5G muestra que la primitiva de retrieval es lo que impulsa la accuracy factual a esta escala. Qwen 2.5 0.5B con Dazzle RAG alcanza 0.630 EM_contains contra 0.105 sin retrieval (6.0 $\times$); Qwen 2.5 1.5B con RAG alcanza 0.735 contra 0.110 sin retrieval (6.7 $\times$). Un modelo de 380 MB con retrieval supera a un modelo de 940 MB (3 $\times$ más grande) sin retrieval en cada métrica factual, end-to-end en un teléfono Android de \$150. El cuello de botella no es el tamaño del modelo, ni el SoC, ni el costo en microsegundos del retrieval; es si el backend permite que el bucle del agente alcance un índice vectorial siquiera.

Keywords base de datos embebida · LLM on-device · agentes móviles · Valkey · HNSW vector search · Apache 2.0

Nota sobre esta versión. Esta es una traducción técnica al español del paper en inglés paper_v2_en.md, mantenida en paralelo al original. La fuente de verdad para arXiv y para todas las tablas / claims experimentales sigue siendo la versión en inglés. Se preservan en inglés los términos técnicos reservados de la literatura (LLM, RAG, HNSW, snapshot cache, key-value, sorted set, HyperLogLog, NEON SDOT, SIMD, in-process, write-through, backend, daemon, thread, lock, atomicity, prefill,

decode, embedding, retrieval, fork, harness, benchmark, footprint, ingest, wrapper, etc.) tal como aparecen en el dominio.

1 Introducción

Los modelos de lenguaje cuantizados de menos de 3 GB hoy corren a tasas interactivas en hardware ARM64 de clase smartphone: Gemma 2 [gemma2] y Gemma 4 [gemma4], Phi-3 mini [phi3], la serie Llama 3 [llama3] (incluyendo Llama 3.2 1B y 3B), MobileLLM [mobilellm], y la serie Qwen 2.5 [qwen25] que usamos en §5.9. El stack de runtime — llama.cpp [llamacpp] con su formato de pesos cuantizados GGUF [gguf], LiteRT-LM [litertlm], MLC-LLM [mlc-llm], ExecuTorch [executorch] — está maduro y alcanza latencia sub-segundo por token decodificado en handsets de \$150.

La **capa de estado** que un agente necesita no ha madurado al mismo ritmo. Por capa de estado nos referimos al lugar donde el agente guarda lo que ha visto entre llamadas de inferencia, coordina entre turnos, y sobrevive reinicios de proceso.

Considere un agente de monitoreo IoT móvil: recolecta lecturas de temperatura, humedad, presión y batería a intervalos; un LLM procesa lotes en checkpoints y produce reportes de síntesis. Entre checkpoints el agente necesita (1) un bounded buffer ordenado en el tiempo sobre las lecturas más recientes, (2) agregados en running (min/max/avg/count) sin reescanear historia, (3) conteo probabilístico para señales de anomalía y cardinalidad, y (4) TTL por campo para mantener el bloque de contexto dentro del presupuesto del prompt. Cada requerimiento mapea limpiamente a una estructura de datos específica: bounded streams, sorted sets y hashes, HyperLogLog, TTL sobre hash fields. Ninguna es exótica. Ninguna es problema de investigación.

Ningún backend en la plataforma las ofrece como primitivas nativas. En Android e iOS las opciones embebidas dominantes — SQLite [sqlite], RocksDB [rocksdb] (un descendiente LSM-tree de LevelDB [leveldb]), LMDB [lmdb], ObjectBox [objectbox4], y el peer embebido analítico DuckDB [duckdb] — exponen entre dos y cuatro estructuras de datos en total: filas, key-value pairs, blob stores, ocasionalmente un índice vectorial. Cada construcción de orden superior (bounded streams, agregados materializados, conteos aproximados, semántica TTL, similarity search) tiene que ser re-implementada en código de aplicación sobre esas primitivas, por cada equipo que las necesita. El código resultante es frágil bajo acceso concurrente. Las garantías de atomicidad que vienen gratis con un servidor in-process maduro se pierden silenciosamente. La misma media docena de bugs se redescubre app tras app.

La aritmética de latencia libera al argumento de la habitual carrera de microbenchmarks. Incluso el backend embebido más lento en nuestra evaluación — SQLite a aproximadamente 3 ms de retrieval en $N = 20\,000$ bajo carga concurrente en un handset Android de \$150 — está tres órdenes de magnitud por debajo de un solo turno de inferencia LLM on-device (1–3 segundos para un modelo de 1–3 miles de millones de parámetros). El retrieval en microsegundos no es lo que mueve la aguja del producto. Lo que la mueve es qué primitivas expone el backend, qué tan ergonómicas son de invocar, y cuánto código pegamento escribe el autor del agente antes de que la capa de estado se comporte.

El eje correcto de comparación para backends de agentes on-device, argumentamos, es **superficie primitiva y ergonoría del desarrollador**, no throughput crudo de microbenchmark. Cuatro piezas de evidencia respaldan esa posición: (a) el envelope de latencia de Dazzle se ubica cómodamente dentro del piso de ruido LLM en cada configuración que probamos; (b) primitiva-por-primitiva Dazzle expone **diez primitivas nativas contra ≤ 4 en cualquier competidor embebido en las mismas plataformas**; (c) una comparación en líneas de código para la misma capa de estado del agente; y (d) una demostración end-to-end de que las primitivas que Dazzle expone habilitan patrones cualitativamente nuevos — small-model + on-device retrieval-augmented generation [lewisrag; karpukhindpr] — que no son alcanzables cuando la única primitiva disponible es un store key-value plano o de filas.

Contribuciones.

1. **Primer port in-process de Valkey a procesos de aplicación Android e iOS:** un transporte self-pipe, un snapshot cache con write-through, y un SPSC ring buffer en Android reemplazan el TCP loopback de Valkey preservando la superficie completa de primitivas y el scripting Lua.
2. **Una contribución de ingeniería medida más dos capas de future-proofing** (§3, §5.4). El snapshot cache write-through es la única capa que mueve throughput sobre la carga Write-Heavy / Read-Light medida — la ablación factorial 2^3 de §5.4 muestra que el worker pool paralelo y el path de dispatch por hash-bucket son no-ops sobre esta carga (dentro del ruido run-to-run) porque el snapshot cache ya absorbe la contención que ellos fueron diseñados para remover. Mantenemos esas dos capas en la arquitectura como headroom de key-space-scaling: bajo benchmarks no corridos en este paper (keyspaces mucho más grandes, múltiples threads escritores, fan-in desde varias producer queues) esperamos que ganen su costo de vuelta, y los números de §5.4 describen las condiciones bajo las que no lo hacen. El auto-mirror post-EVAL que mantiene visible

al cache el estado mutado por Lua, y el transporte in-process en sí, son las dos contribuciones de ingeniería adicionales de interés independiente documentadas en §3.

3. **Caracterización del envelope de latencia** sobre doce backends, con N de 200 a 20 000, en un handset Android de presupuesto (Moto G35 5G, Unisoc T760) y un iPhone 12 Pro físico — paridad completa de bench-coverage (cada backend corre en ambas plataformas; iOS retiene el transporte self-pipe de Phase-0 — ver §6.3 — y las optimizaciones SPSC ring buffer / io_uring son Android-only), incluyendo el port nativo iOS de ObjectBox 5.3 cableado en esta revisión (entidades, bindings generados con Saurcery, y una test suite XCTest corrible en simulador en `experiment/storage/ios/Tests/ObjectBoxTests.swift`).
4. **Comparación de superficie primitiva y complejidad de desarrollo** contra cinco alternativas embebidas (SQLite, LMDB, RocksDB, ObjectBox, InMemory) más una referencia de Valkey-sobre-TCP: diez primitivas nativas contra ≤ 4 , con medidas concretas de LOC para la misma capa de estado del agente (§5.6).
5. **Demostración end-to-end** vía una ablación 2×2 RAG sobre 200 queries NQ (§5.9, Tabla 15). Agregar la primitiva vectorial de Dazzle eleva EM_contains 6.0× sobre Qwen 2.5 0.5B (0.105 → 0.630) y 6.7× sobre Qwen 2.5 1.5B (0.110 → 0.735); la celda de small-model-with-retrieval supera a la de large-model-without-retrieval en cada métrica factual. El resultado habla de qué se vuelve implementable cuando la primitiva correcta está presente, no de un delta en microsegundos sobre un competidor.
6. **Distribución pública del SDK** de `dazzle-sdk 1.0.0-beta.4` sobre cuatro registries estándar (Maven Central, pub.dev, npm, Swift Package Manager), con cinco adaptadores LLM detrás de una interfaz `LLMClient` común (Apéndice A). Apache-2.0 (Dazzle) / BSD-3-Clause (porciones derivadas de Valkey).

2 Contexto y motivación

2.1 Requerimientos de estado para un agente LLM on-device

Un LLM-como-agente difiere de la inferencia de un solo turno en que debe:

- Mantener una ventana de observación bounded (buffer circular con desalojo automático).
- Trackear running aggregates (min/max/avg sin re-scan $O(N)$).
- Contar aproximadamente eventos distintos (HyperLogLog en 12 KB con $\sim 0.8\%$ error relativo [`@hyperloglog`] vs $O(N)$ exacto).
- Aplicar TTL por campo a observaciones obsoletas (expiración automática sin un cron en la app).
- Señalizar entre componentes (Pub/Sub sin polling).

Estas primitivas existen desde hace una década en Redis/Valkey. Lo nuevo es embeberlas **dentro del proceso de la app móvil** para que el salto de red entre agente y store desaparezca.

2.2 Primitivas nativas por backend

Tabla 1 — Disponibilidad por primitiva por backend embebido. Cada celda registra *cómo* se alcanza la primitiva, no solamente *si* es alcanzable. **N** = llamada nativa de API tipada que el motor mismo provee. **E** = extensión oficial provista por el proyecto upstream (e.g., *RTree de SQLite, en la amalgamation desde 2008*). **A** = *re-implementación a nivel de aplicación — el desarrollador escribe código pegamento sobre primitivas más bajas en el motor*. **T** = *extensión de tercero distribuida separadamente del motor*. La fila “Total Native” cuenta solo **N**; **E**, **A** y **T** significan *que la primitiva es alcanzable** pero con costo de ingeniería distinto, capturado cuantitativamente por el diferencial de LOC en la Tabla 9 y discutido explícitamente en §6.3.

Primitiva	Dazzle	SQLite	RocksDB	ObjectBox	LMDB
Bounded stream con MAXLEN	N	A	A	A	A
Sorted sets con range query	N	A ¹	A	N	A
Atomic float increment	N	A ²	A	A	A
TTL por campo	N	A	A	A	A
HyperLogLog	N	A	A	A	A
Geo indexing	N	E ³	A	A	A
Pub/Sub	N	A	A	N□	A
Server-side scripting (Lua)	N	A	A	A	A
Vector search (HNSW)	N	T□	A	N	A
Iteración basada en cursor	N	N	N	N	N
Total Native (N)	10	1	1	4	1

¹ Implementable vía `ORDER BY ... WHERE ... BETWEEN` en SQL de la app. ² Implementable vía `UPDATE ... SET v = v + ?` dentro de una transacción. ³ R*Tree es una extensión oficial de SQLite incluida dentro de la amalgamation desde 2008.

□ El `DataSubscription` de `ObjectBox` es una API de 1-call tipada para consumidores de notificación de cambios; lo contamos como un equivalente nativo de pub/sub para el caso de uso del bucle del agente (un solo consumidor suscrito a un stream tipado de cambios), aun cuando es observer-pattern en lugar de topic-routed. □ `SQLite` no tiene una primitiva vectorial nativa ni oficial; el vector search lo proveen solo extensiones de tercero (`sqliteai/sqlite-vector` comercial, `asg017/sqlite-vec` open-source), que benchmarkearemos separadamente en §5.8 como peers comerciales en lugar de como feature nativo de `SQLite`.

El conteo del headline (10 vs ≤ 4 nativas) mide **cuántas primitivas el autor del agente puede alcanzar con una sola llamada tipada de librería** — el eje de “superficie primitiva” de la tesis Dazzle. Las primitivas marcadas **E**, **A** o **T** en backends no-Dazzle son *implementables*; la pregunta es el costo de ingeniería, que medimos directamente en §5.6 (Tabla 9: 175 LOC Android / 186 LOC iOS para Dazzle vs 200–290 LOC para los equivalentes basados en `SQLite`). Un revisor leyendo la Tabla 1 como “primitivas que existen en cualquier parte del ecosistema de este motor” llega a un gap mucho más pequeño. Esa es una pregunta distinta (y más débil) que la que la Tabla 1 está estructurada para responder, y §6.3 Limitaciones deja la elección del eje explícita. Los experimentos de performance que siguen respaldan el argumento cuantitativo, incluyendo el benchmark vectorial head-to-head contra `ObjectBox 4.x` y `SQLiteAI sqlite-vector 0.9.95` en §5.8.

2.3 Por qué embeber Valkey, y por qué como fork

Valkey fue diseñado para servidores Linux: daemon long-lived, TCP loopback, asunciones POSIX de GNU libc, shutdown via `exit()`. Ninguna sobrevive un port a un proceso de app móvil. Dazzle aplica tres cambios como overlay del fork. El primero es **portabilidad**: shims para Bionic libc de Android y para el SDK de Apple. El segundo es **lifecycle**: el servidor no puede matar a su proceso host. El tercero es **transporte in-process**: el TCP loopback es puro overhead cuando cliente y servidor comparten el address space.

El upstream de Valkey no se vendoriza. Lo descargamos en un tag fijo y le aplicamos tres diffs (~180 líneas en total) antes de compilar. Publicar solo los diffs preserva la licencia BSD-3-Clause de Valkey; el código original de Dazzle (en `core/` y `sdk/`) es Apache-2.0.

3 El sistema Dazzle

3.1 Arquitectura

Dazzle se organiza en tres capas:

- **core/** (Apache-2.0). Transporte in-process (`core/transport/dazzle_transport.c`) + snapshot cache + worker pool (Android). C puro, compilado con el Valkey patcheado.
- **versions/** <ver> / **patches/** (diffs de build-time). Tres patches: Android (shims de Bionic), iOS (ajustes para el SDK de Apple + un `malloc_zone_t` custom para reportar RSS aislado), y un hook de 14 líneas en `server.c` que inserta `dazzle_direct_init()` después de `InitServerLast()`.
- **sdk/android/**, **sdk/ios/** (Apache-2.0). Bridges JNI + Kotlin (AAR) y bridges C + Swift (XCFramework).

3.2 Transport path

El event loop de Valkey corre sobre un pthread dedicado. El thread de la aplicación se comunica vía:

- **Pipe in-process.** El thread de la app hace `write()` de un pointer de 8 bytes a un `DirectRequest`, muy por debajo de `PIPE_BUF` (≥ 512 bytes por POSIX, 4 096 en Linux), así que el kernel garantiza entrega atómica sin lock del lado escritor. El event loop despierta en `read()`, ejecuta `call()` con un cliente fake, y señala el condvar con la respuesta RESP.
- **Snapshot cache write-through.** Cada comando mutador que cruza el pipe actualiza un cache in-process bajo `rwlock` antes de liberar al caller. Las lecturas subsiguientes adquieren el `rdlock` y retornan valores directamente, sin wake-up del event loop. El pipe es síncrono, así que para cuando una lectura se dispara el cache ya refleja cada escritura previa: **cero staleness por construcción**.
- **Worker pool (Android).** 2–4 threads adicionales absorben lecturas concurrentes bajo `rwlocks` striped por slot cuando el flag de entorno `DAZZLE_PARALLEL_READS=1` está activo.

3.3 Auto-mirror post-EVAL

Los scripts Lua (EVALSHA) ejecutan sus escrituras internas a través del `call()` de Valkey, que no dispara el hook del snapshot-mirror. Sin trabajo adicional, los backends que escriben campos dentro de un script Lua y los leen después pagarían el costo pipe-HMGET en cada lectura. Dazzle hidrata el cache automáticamente después de cada EVAL: itera sobre los KEYS declarados del script, re-lee cada hash a través de la API de kvstore, y hace upsert de sus campos al bucket correspondiente. Un backend que escribe 8 campos dentro de un Lua EVALSHA los ve reflejados en el snapshot en la siguiente lectura, sin trabajo adicional en el SDK.

4 Diseño experimental

4.1 Carga de trabajo

Agente sintético de monitoreo IoT: 200 lecturas con cinco campos (temperatura, humedad, presión, batería, vibración), 11 anomalías inyectadas, 10 checkpoints de inferencia espaciados uniformemente. Dos condiciones: **Stateless** (el modelo recibe solo las últimas 20 lecturas) y **Augmented** (las 20 lecturas + un bloque de contexto materializado con agregados sobre la ventana completa).

4.2 Backends

Cinco alternativas embebidas (SQLite, LMDB, ObjectBox, RocksDB, InMemory) más una referencia Valkey-sobre-RESP-TCP (el servidor Valkey 8 sin modificaciones con loopback localhost, incluido como baseline de “transport overhead”) y siete variantes de Dazzle exponiendo distintos paths de primitivas: básico, Lua, Pipeline, HFE, HLL, **Precompute** (agregados materializados) y **Vector** (búsqueda vectorial HNSW). Doce backends en total por dispositivo, con **paridad completa de bench-coverage** sobre los sweeps storage-only y vector-bench en esta revisión (cada backend corre en ambas plataformas; el port iOS de ObjectBox 5.3 aterriza en §5.6, y el path Dazzle-Vector corre en ambas plataformas vía el preset unificado `paper384_scale`).

4.3 Dispositivos

Mediciones físicas en dos dispositivos:

- **Moto G35 5G** (Unisoc T760, 8×ARM @ 2.0/2.2 GHz, 4 GB LPDDR4X, Android 14). El handset Android de presupuesto / referencia.
- **iPhone 12 Pro** (Apple A14 Bionic, 6 GB LPDDR4X, iOS 26.3). El punto de validación cross-platform.

Los runs storage-only se hacen sobre ambos dispositivos. Los runs vector-bench se hacen sobre el Moto G35 5G y, en esta revisión, también sobre el iPhone 12 Pro vía el preset `paper384_scale`. El RAG end-to-end de §5.9 cubre dos SoCs Android físicos (Moto G35 5G + Moto G30; §5.9.5) y aún no iPhone 12 Pro.

4.4 Métricas

- **Ingest**: microsegundos por lectura (per-reading ingest μ s).
- **Retrieval**: microsegundos promedio sobre la ventana de retrieval-sample, p50 y p95.
- **Footprint**: bytes en disco después de los 200 ingests (`stat.st_blocks` × 512, equivale a `du -k`).
- **Vector**: p50 / p95 / p99 search latency sobre 100 queries por celda en estado estable warm; recall@k contra una verdad brute-force SQLite.
- **RAG E2E**: EM_short, EM_contains, F1_short, F1_passage por query, agregados sobre 200 queries de NQ.

Bootstrap percentile-method ($B = 10\,000$, seed = 42) [`@efronbootstrap`; `@davisonhinkley`] sobre las arrays per-query para los CIs reportados en las tablas. Los scripts de re-derivación están en `research/scripts/bootstrap*_lats.py`.

5 Evaluación

5.1 La memoria externa habilita la síntesis

Tabla 2 — Accuracy de síntesis factual sobre estadísticas globales (checkpoint final).

Condición	Total de lecturas	Conteo de anomalías	Temperatura media	Score
Stateless	– (confabula ~50)	– (confabula 2–3)	– (confabula ~21 °C)	0/3
Augmented (cualquier backend)	Y (200)	Y (11)	Y (22.4 °C)	3/3

Este es el hallazgo empírico central del paper. Sin memoria externa el modelo no tiene acceso a datos fuera de su ventana de contexto actual (las últimas 20 lecturas), así que las “estadísticas globales” que produce son confabulaciones. Con un bloque de contexto materializado, el modelo lee los valores exactos y los reproduce. El backend específico es irrelevante para este hallazgo. Lo que importa es que la memoria exista y que el contexto sea preciso.

La implicación para el diseño de agentes es directa: **la capa de memoria externa es infraestructura obligatoria para cualquier tarea que razone sobre estado acumulado**, no una optimización opcional. La elección del backend después se reduce a performance, superficie primitiva, y ergonomía.

5.2 Caracterización del envelope de latencia

Esta sección establece el envelope de latencia en el que un backend de agente on-device debe operar. No es una declaración de ganador de microbenchmark. Medimos cada backend en dos regímenes: un sweep storage-only en $N = 200$ lecturas en ambos dispositivos físicos (Tabla 3), y una referencia bajo carga concurrente en $N = 20\,000$ (1 escritor + 1 lector, Moto G35 5G) llevada como un stress test de estado estable. Los dos juntos cubren el envelope operativo realista de un agente on-device long-running.

Nota metodológica para las Tablas 3–6. Las filas de la familia SQLite (sqlite, sqlite-optimized, sqlite-p-recompute) vienen de un sweep de mitigación aislado (Android: 3 rondas por backend, orden randomizado; iOS: 3 rondas, dataset dataset_iot_baseline). Las filas SQLite de la familia vector (sqlite-vec y variantes SQLiteAI) vienen del harness vectorial alineado en $\text{dim} = 384$, $k = 10$, p50 search latency sobre 100 queries. El path SQLiteAI iOS requirió vendorizar la amalgamation de SQLite con `SQLITE_ENABLE_LOAD_EXTENSION=1` dentro del bench target, porque el libsqlite3 del sistema de Apple viene con extension loading deshabilitado — esto está documentado como parte del artefacto (§8.1, experiment/backends/ios/sqlitevectorai/svai_ios.c) y se validó end-to-end con la suite XCTest corriendo en simulador antes del run en device.

Tabla 3 — Storage backends, envelope ingest/retrieval en $N = 200$ en dispositivos físicos (ingest μs por lectura / retrieval μs promedio).

Backend	Moto G35 5G ingest / retrieval	iPhone 12 Pro ingest / retrieval
Dazzle (default)	2 889 / 2 132	185 / 411
Dazzle-Lua	1 345 / 1 824	181 / 251
Dazzle-Pipeline	1 331 / 1 959	143 / 444
Dazzle-HFE	2 312 / 1 893	177 / 389
Dazzle-HLL	2 844 / 2 491	185 / 454
Dazzle-Precompute	1 404 / 34.7	267 / 129
Valkey 8 (RESP-TCP)	3 754 / 3 320	432 / 1 474
SQLite (default)	251.95 / 1 061.3	61.94 / 268.7
SQLite-Optimized	59.09 / 899.4	23.64 / 199.4
SQLite-Precompute	207.77 / 75.0	317.10 / 27.6
LMDB	172 / 641	100 / 346
RocksDB	294 / 922	169 / 424
ObjectBox ‡	1 839 / 778	4 840 / 638
In-memory (struct)	9.97 / 282	5.35 / 204

‡ El ingest de ObjectBox iOS bajó de 24 780 $\mu\text{s}/\text{r}$ a 4 840 $\mu\text{s}/\text{r}$ ($5.1\times$ speedup) una vez que envolvimos el cuerpo de cada `ingest()` y `storeCheckpointDecision()` en `store.runInTransaction { ... }`. El port Kotlin corre ~10 calls de `box.put()` / `box.query()` por lectura y depende del write-tx batching implícito por-call de ObjectBox-Java para alcanzar 1 839 $\mu\text{s}/\text{r}$; ObjectBox-Swift abre una transacción de escritura nueva por cada call (`lock + journal append + fsync`), así que las mismas 10 llamadas sin coalescing pagan el overhead del lock $10\times$. El gap remanente de $\sim 2.6\times$ iPhone-vs-Moto es consistente con el allocator iOS y el overhead FFI observado en otras partes de la tabla (ver la anomalía del footprint Dazzle iOS discutida en §6.3); no es un bug del bench-harness.

Tabla 4 — Vector backends, envelope ingest/retrieval en $N = 200$ en dispositivos físicos (ingest μs por lectura / p50 search latency μs , $\text{dim} = 384$, $k = 10$).

Backend	Moto G35 5G ingest / search	iPhone 12 Pro ingest / search
Dazzle-Vector (HNSW)	74 / 65	25.17 / 18
sqlite-vec default	23.62 / 916.0	27.64 / 196

Backend	Moto G35 5G ingest / search	iPhone 12 Pro ingest / search
sqlite-vec optimized	9.66 / 860.0	20.67 / 193
sqlite-vec precompute	9.35 / 816.7	19.72 / 181
SQLiteAI default	6.08 / 135.3	6.90 / 29
SQLiteAI optimized	5.98 / 135.0	6.82 / 29
SQLiteAI precompute	5.17 / 111.3	7.27 / 23

Dazzle-Vector en el Moto G35 5G ahora reporta **74 μ s/r ingest, 65 μ s p50 search a recall 1.000 (HNSW, ef = 10)** en $N = 200$. La celda previa – / – en esta fila se debió a un bug del harness en `SqliteBruteForceVector.create()` (la truth-source SQLite brute-force nunca borraba su database entre runs porque el delete de archivo apuntaba al directorio incorrecto, así que la truth de top-k por config se computaba contra ~20 000 docs obsoletos acumulados a través de bench launches previos; solo la última config en cualquier sweep recuperaba fortuitamente recall por encima del piso de 0.95). Ambos fixes aterrizaron en esta revisión: el delete de la truth-source ahora resuelve a `context.getDatabasePath(...)` y `VectorBenchmark` emite FLUSHALL entre configs y entre variantes de motor Dazzle así que cada medición es per-engine y per-config en aislamiento. El fix está en el commit 1e3d5f5 de `experiment/backends/android/core/SqliteBruteForceVector.kt + VectorBenchmark.kt`, y el bench post-fix está committeado en `research/benchmarks/results/Moto_G35_5G/vector/vecbench_moto_g35_5G_1777369156656.json` (SHA-256 5a64d3692da166d96306d456697e43bb89c27c07b515e253346c5b33bc5c9b5b). Las Tablas 4, 5, 11 y el N-sweep de §5.8.4 / companion-report leen de este único JSON, así que los números celda-por-celda y la narrativa de recall vienen de un solo run en device, no de una mezcla de snapshots pre-fix y post-fix.

Observación 1. Dazzle-Precompute fija el piso alcanzable cuando los agregados materializados se exponen como primitiva nativa. El retrieval promedia 34.7 μ s en $N = 200$ en Moto G35 5G y 47 μ s en $N = 20\,000$ bajo carga concurrente. El costo de retrieval es plano en N porque el bloque de contexto materializado se reconstruye en el path de escritura y se lee con una copia de campo de tiempo constante. En iPhone 12 Pro el retrieval aterriza en 129 μ s. Estos números son la cota inferior que un backend puede alcanzar cuando el patrón de lectura del agente está compilado dentro del schema, no lo que cualquier backend “podría” alcanzar en principio.

Observación 2. Una concesión honesta que la tabla ahora hace explícita, sobre las nueve variantes de la familia SQLite (default/optimised/precompute sobre storage SQLite, sqlite-vec, y SQLiteAI): el retrieval Android se mueve de 1 061.3 μ s (sqlite default) a 899.4 μ s (sqlite-optimized) y a 75.0 μ s (sqlite-precompute). Eso cierra la mayor parte del gap de storage-latency y refuerza el framing del paper. El diferenciador no es un límite intrínseco del algoritmo SQLite, sino cuánta ceremonia de materialización y código de mantenimiento debe poseer la aplicación.

La Observación 3 es la que realmente importa. Incluso la latencia de retrieval más alta del envelope (SQLite a 3 374 μ s bajo carga concurrente en Moto G35 5G) es aproximadamente el 0.0001 % de un solo turno de inferencia Gemma 4 E2B [@gemma4] (1–3 segundos). La diferencia perceptible para el usuario entre 50 μ s y 3 374 μ s en la capa del agente es cero; ambos quedan empujados por la llamada de inferencia que se sienta inmediatamente después del retrieval. Las comparaciones en microsegundos no son el eje sobre el cual elegir un backend. Los criterios dominantes son la superficie primitiva (Tabla 1, §2.2) y la complejidad de desarrollo requerida para entregar una capa de estado funcional (§5.6).

5.2.1 Por qué seguimos reportando los microsegundos exactos

Un revisor puede razonablemente preguntar: si cada retrieval está por debajo del piso de ruido de inferencia y las comparaciones en microsegundos no son el eje de elección, ¿por qué §5 gasta doce tablas enumerando microsegundos? Dos razones, ambas independientes de la tesis del agente:

(i) **Consumidores no-LLM pueden compartir la capa de storage.** Aunque este paper no los benchmarkea, el mismo path de código Dazzle es estructuralmente compatible con dashboards de analítica on-device, pipelines de pre-agregación de sensores, y capas de resolución de conflictos de sync — cargas donde las primitivas de retrieval (agregados materializados, bounded streams, HyperLogLog, HNSW) son las mismas pero donde la latencia de retrieval *no* está dominada por un forward pass de LLM. Reportamos los números absolutos en microsegundos para que un lector evaluando esas cargas pueda extraer la fila relevante de la Tabla 3 / Tabla 5 / Tabla 11 directamente sin re-correr el bench. No hacemos ningún claim competitivo sobre la posición de Dazzle en esas cargas en este momento.

(ii) **Los números absolutos son un sanity check sobre la arquitectura.** Un backend que se vaya a 100 ms+ en $N = 200$ (un orden de magnitud por encima de lo que reportamos aquí) sugeriría una regresión digna de investigar más allá del piso de ruido LLM. El patrón Write-Heavy / Read-Light está supuesto a mantener el retrieval acotado; si una revisión futura rompe eso, la columna exacta de microsegundos en T3 es donde la regresión se manifiesta. La misma lógica para la ablación de §5.4 y la tabla de evolución de performance de §5.7 en el companion report: esos números

son cómo sabemos que el patrón arquitectónico se mantiene intacto a través de revisiones, no cómo recomendamos elegir un backend.

Esta sección por tanto establece que todos los backends medidos se ubican dentro del envelope aceptable para un agente LLM on-device. El resto de la evaluación se lee en dos tracks: **(a)** para un lector centrado en el agent-loop, la superficie primitiva (Tabla 1) y la complejidad de desarrollo (Tabla 9) impulsan la selección de backend; **(b)** para un lector no-LLM, los números por motor en microsegundos son el input directo. Ambas lecturas vienen de los mismos datos; la diferencia es qué eje tratará el lector como el headline.

5.3 Retrieval constante en N y footprint de almacenamiento

Tabla 5 — Promedio de latencia de retrieval a través de tamaños de dataset, Moto G35 5G (μ s). Sweep en $N \in \{200, 1\,000, 5\,000, 20\,000\}$. Cada celda en la Tabla 5 y la Tabla 5b es la media aritmética por-run de la ventana de retrieval-sample (retrieval_avg_us en cada scale_<backend>_*.json); para backends con múltiples sweep runs en el repo (típicamente 3–4), la celda es la mediana de esas medias por-run. La columna correspondiente retrieval_p50_us también está persistida en cada JSON para cualquier lector que prefiera la mediana sobre la media, pero los valores de la tabla a lo largo de esta sección son medias.

Backend	N = 200	N = 1 k	N = 5 k	N = 20 k
Dazzle-Precompute	37	29	29	34
Dazzle-Incremental	325	163	155	146
InMemory	663	314	273	317
SQLite (default)	1 061.3	739.1	717.4	721.6
SQLite-Optimized	899.4	508.1	514.5	505.4
SQLite-Precompute	75.0	59.8	62.1	60.6
sqlite-vec default	916.0	1 445.7	7 271.0	27 850.3
sqlite-vec optimized	860.0	1 434.7	7 145.3	28 574.7
sqlite-vec precompute	816.7	1 430.7	7 421.3	26 505.3
SQLiteAI default	135.3	303.0	1 475.0	9 812.3
SQLiteAI optimized	135.0	302.3	1 591.7	9 569.7
SQLiteAI precompute	111.3	233.3	889.0	3 071.7
LMDB	1 130	841	1 398	1 986

Tabla 5b — Promedio de latencia de retrieval a través de tamaños de dataset, iPhone 12 Pro (μ s). Misma métrica (media aritmética de la latencia per-sample de retrieval, retrieval_avg_us) y misma grilla de sweep que la Tabla 5.

Backend	N = 200	N = 1 k	N = 5 k	N = 20 k
Dazzle-Precompute	25.4	17.8	17.8	17.8
Dazzle-Incremental	139.2	63.7	63.3	63.2
InMemory	148.9	149.3	106.4	55.8
SQLite (default)	73.4	47.5	47.7	46.7
SQLite-Optimized	75.9	38.2	32.9	33.1
SQLite-Precompute	6.88	3.75	3.79	3.83
sqlite-vec default	196	548	3 578	15 038
sqlite-vec optimized	193	547	3 535	15 200
sqlite-vec precompute	181	548	3 535	15 145
SQLiteAI default	29	96	441	2 850
SQLiteAI optimized	29	96	440	2 842
SQLiteAI precompute	23	79	355	1 407
LMDB	167.4	67.2	46.9	85.8

Las Tablas 5 y 5b deben leerse como un resultado de patrón de implementación, no como una carrera de backends. La propiedad relevante es **retrieval constante en N** cuando el sistema sirve agregados materializados en lugar de reconstruir contexto desde historia cruda en query time. La fila Dazzle-Precompute en la Tabla 5 es la mediana de las medias por-run de cuatro sweep runs. Dazzle-Precompute y Dazzle-Incremental proveen este patrón nativamente: el trabajo de agregación se paga en escritura, y el retrieval lee estado materializado acotado. SQLite también puede realizar retrieval cuasi-constante cuando el mismo patrón se implementa explícitamente. Por tanto, el comportamiento constante en N es una propiedad del approach de agregados materializados, no una propiedad propietaria de un solo motor.

5.3.1 Footprint de almacenamiento después de 200 ingests

Tabla 6 — Footprint en disco después de 200 ingests, por dispositivo (KB).

Backend	Moto G35 5G (KB)	iPhone 12 Pro (KB)
Dazzle (default)	6.7	153.3
Dazzle-Lua	6.6	153.3
Dazzle-Pipeline	6.7	153.3
Dazzle-HFE	6.6	153.3
Dazzle-HLL	7.0	177.6
Dazzle-Precompute	7.7	153.5
Valkey 8 (RESP-TCP)	7.9	177.4
LMDB	72.0	176.0
ObjectBox	96.0	268.0
RocksDB	4 515.8	104.0
SQLite	374.2	3 635.2
SQLite-Optimized	494.6	3 391.5
SQLite-Precompute	495.6	176.6
sqlite-vec default	4.1	4.0
sqlite-vec optimized	4.1	4.0
sqlite-vec precompute	4.1	4.0
SQLiteAI default	12.3	12.0
SQLiteAI optimized	12.3	12.0
SQLiteAI precompute	12.3	12.0

El ratio de headline es **Dazzle vs SQLite**:

- Moto G35 5G: 6.7 KB vs 374.2 KB — **56× más pequeño**
- iPhone 12 Pro: 153.3 KB vs 3 635.2 KB — **24× más pequeño**

El footprint es la restricción binding sobre hardware IoT y móvil de presupuesto donde el budget de flash y el bandwidth de DRAM son ambos escasos. Un payload **24–56× más pequeño** es la diferencia entre que los datos de Dazzle quepan en un puñado de líneas de caché L2 por retrieval, versus barrer múltiples páginas de SQLite por query — lo que se compone hacia atrás en la imagen de retrieval-latency de §5.2.

5.4 Ablación factorial 2³: ¿qué capa contribuye?

El stack Dazzle compone tres optimizaciones independientes: snapshot cache (on/off), bucket dispatch por hash (1 bucket vs 16), worker pool paralelo (off/on). Medimos seis combinaciones válidas sobre la misma carga: K = 8 agentes, mix 80/20 read/write, 15 s por celda.

Tabla 7 — Throughput en K = 8, Moto G35 5G (ops/s, mix 80/20 read/write, 15 s por celda).

Backend	baseline	workers	snap-ser	snap-par	hash-ser	hash-par
dazzle-incremental	12 106	9 604	28 897	28 154	27 926	28 304
dazzle-precompute	19 676	10 988	38 830	38 754	38 367	38 156

Tres observaciones cuantificadas:

1. **El snapshot cache solo es la capa de throughput.** snap-linear-serial (snapshot on, 1 bucket, sin workers) es el pico en ambas filas: **38 830 ops/s** para precompute y **28 897 ops/s** para incremental. Capear el hash-index de 16 buckets y el worker pool paralelo encima del cache (la columna “full-stack” hash-par) realmente entrega **38 156 / 28 304 ops/s** — snap-ser está 1.8 % por encima de hash-par para precompute y 2.1 % por encima para incremental. El stack completo pierde, no gana, contra snap-ser; los deltas están dentro de la varianza run-to-run, así que la lectura práctica es “el snapshot cache por sí solo es suficiente y las otras dos capas no agregan nada medible sobre esta carga”.
2. **Los workers solo regresan performance.** Sin un cache contra el cual hacer dispatch, el worker pool es puro overhead de queueing: 44 % más lento para precompute, 21 % más lento para incremental.
3. **El hash-index es future-proofing.** El keyspace de 4–5 keys del benchmark cabe trivialmente en un solo bucket; el dispatch O(1) se vuelve visible solo cuando el keyspace crece a docenas de keys o cuando los nombres de campo comparten prefijos largos.

En una línea: **el snapshot cache es la única capa que mueve throughput sobre esta carga. El worker pool paralelo y el dispatch hash-index son no-ops aquí y solo ganan su costo sobre cargas con un keyspace más grande o más contenido.**

5.5 Validación cross-platform: iPhone 12 Pro

El mismo stack Dazzle corrido en un iPhone 12 Pro físico (iOS 26.3, A14 Bionic) y un Moto G35 5G físico (Android 14, Unisoc T760), 200 lecturas, un solo escritor + 100 muestras de retrieval (mismo protocolo storage-only que §5.2).

Tabla 8 — Resumen Dazzle cross-platform, Moto G35 5G vs iPhone 12 Pro (N = 200, un solo escritor + 100 muestras de retrieval).

Métrica	Moto G35 5G	iPhone 12 Pro
Dazzle-Precompute ingest ($\mu\text{s}/\text{r}$)	1 404	267
Dazzle-Precompute retrieval avg	34.7 μs	129 μs
Dazzle-Precompute retrieval P50	34.3 μs	139 μs
Dazzle-Precompute retrieval P95	42.2 μs	189 μs
Dazzle-default retrieval avg	2 132 μs	411 μs
Ganancia de retrieval (precompute/default)	61×	3.2×
Footprint (Dazzle default)	6.7 KB	153.3 KB
Footprint vs SQLite	56× menor	24× menor

Tres observaciones sobre el comportamiento cross-platform:

1. **La forma arquitectónica generaliza.** Dazzle-Precompute le gana al path Dazzle default en ambas plataformas — el trade-off Write-Heavy / Read-Light se mantiene en ambas direcciones del par SoC + OS. El snapshot cache paga en cada lectura sin importar dónde corra.
2. **Los números absolutos de retrieval son sensibles a la plataforma.** Moto G35 5G aterriza en 34 μs P50; iPhone 12 Pro en 139 μs P50. El gap de 4× lo impulsa el path RESP del Valkey-fork in-process en iOS (tokio runtime + bridge Rust→Swift por retrieval), no el snapshot cache en sí. El path Android usa un bridge JNI más delgado con menos hops por call.
3. **La dirección del ingest se invierte.** El Moto necesita 1 404 μs por lectura; el iPhone necesita 267 μs (5.3× más barato en iPhone). Los cores más rápidos del A14 Bionic más el bandwidth LPDDR4X tragan la secuencia per-reading de XADD + HINCRBYFLOAT + HSET más rápido que el tier de presupuesto Unisoc T760.

El resumen: la **contribución arquitectónica generaliza** sobre hardware y OS (el costo se desplaza de read a write, el snapshot cache absorbe N, el footprint se mantiene a escala de un solo motor), mientras que **los números absolutos varían por SoC y stack de runtime**. Incluso sobre el path de retrieval iPhone más lento, el P95 se mantiene bajo 200 μs . Eso es tres a cuatro órdenes de magnitud bajo el forward pass LLM on-device ($> 10^6 \mu\text{s}$ en cualquier dispositivo), que sigue siendo el único término que importa al nivel del agent-loop.

5.6 Complejidad de desarrollo

Tabla 9 — Líneas de código por backend, desagregadas por plataforma (SLOC: blanks y líneas de puro comentario excluidas; los counts Kotlin usan el archivo Android *ContextManager.kt en experiment/backends/android/ y los counts Swift usan el archivo iOS *ContextManager.swift en experiment/backends/ios/. Menor es mejor; cada fila implementa la misma superficie de capa de estado del agente).

Backend	Android (Kotlin) SLOC	iOS (Swift) SLOC	Suma (ambas)	Estilo de API
Dazzle	175	186	361	Comandos de primitivas tipados
InMemory	174	172	346	Manipulación directa de colecciones
LMDB	200	227	427	API byte-buffer
RocksDB	203	227	430	API byte-buffer con options
ObjectBox	233	245	478	Anotaciones de schema + DSL
SQLite	268	292	560	SQL + cursor mapping

El desglose por dos plataformas importa porque el port Android y el port iOS de un backend se trackean entre sí dentro de ~30 SLOC para cada fila excepto SQLite (+24 en iOS, mayormente marshalling de result-row con C-API que la API Cursor de Android oculta). El ordering relativo es estable a través de plataformas: Dazzle es el backend más bajo no-InMemory en ambas, SQLite es el más alto, y el gap entre Dazzle y SQLite es ~93 SLOC en Android y ~106 SLOC en iOS — ligeramente más amplio en iOS.

Dazzle requiere el menor número de líneas porque su API tipada (XADD, HMGET, PFADD) expresa directamente las operaciones del dominio del agente sin schema translation ni cursor parsing.

5.7 Evolución de performance (resumen)

El stack actual es el resultado de cinco rediseños de transporte in-process. La contribución individual más grande es el **auto-mirror post-EVAL (+189 % sobre throughput de retrieval incremental** en $K = 8$, Moto G35 5G, mix 80/20 read-write), que hidrata el snapshot cache desde escrituras Lua-internas sin ceremonia manual. Agregar el snapshot index buckedeado, el worker pool paralelo, y el HSET inline en el script Lua contribuye un $\sim 14\%$ adicional sobre precompute. La tabla completa versión-por-versión (baseline 9 684 ops/s $\rightarrow$ final 28 057 ops/s en incremental, 34 356 $\rightarrow$ 38 156 en precompute) vive en §1 del companion engineering report (research/paper/companion_engineering_report.md). Cada optimización fue verificada como una contribución independiente; el cambio se persiste en el repo y en el JSON de benchmark archivado, no se pierde a través de revisiones.

5.8 Primitiva de búsqueda vectorial: envelope y operating points

El resultado que importa en esta sección es un envelope claim, no un speed-competition claim: **la búsqueda vectorial HNSW de Dazzle entrega retrieval sub-milisegundo a recall ≥ 0.95 a lo largo del rango operativo estándar de mobile RAG** ($\dim \leq 384$, $N \leq 10\,000$). Eso pone a Dazzle en la misma clase algorítmica que ObjectBox 4.x, el peer comercial mobile-first con soporte HNSW nativo: ambos son HNSW [`@hnsw`] con búsqueda esperada $O(\log N)$.

SQLiteAI sqlite-vector v0.9.95, la extensión SQLite comercial production-shipping al cierre de Q1 2026, expone un linear scan acelerado por SIMD cuantizado (`vector_quantize_scan`) como su único query path optimizado; HNSW no es user-accessible en esta versión. Incluir SQLiteAI es informativo como referencia de lo que los desarrolladores móviles del ecosistema SQLite encuentran hoy, pero esta comparación abarca dos clases algorítmicas ($O(\log N)$ vs $O(N)$); el gap resultante refleja esa asimetría, no la calidad de ingeniería de ninguna implementación.

El contrato del harness para cada celda de recall floor / operating-point en esta sección está documentado, auditado, y post-mortemado en el Apéndice B (research/paper/appendix_b_harness_postmortem.md). Cada celda en las Tablas 4, 11 y 12 viene del run post-fix archivado en research/benchmarks/results/Moto_G35_5G/vector/vec_bench_moto_g35_5G_1777369156656.json (commit 1e3d5f5, SHA-256 citada en §5.2).

5.8.1 5.8.1 Setup — dos presets de harness

La evaluación vectorial corre el mismo harness (`VectorBenchmark.kt` en Android, `VectorBenchmark.swift` en iOS) contra dos grillas de configuración distintas. El resto de §5.8 cita cualquiera dependiendo de la pregunta a responder:

Preset	Configs	Usado en	Qué responde
DEFAULT_CONFIGS	9 (3 $\dim \times 3\,N$)	§5.8.3 envelope claim	“¿Dazzle se mantiene sub-milisegundo a lo largo del rango mobile RAG estándar ($\dim \leq 384$, $N \leq 10\,000$)?”
vector-bench-paper384-scale (Android) / paper384_scale (iOS)	4 (1 $\dim \times 4\,N$)	T11 + T12 + T13 + T14	“¿Cuál es el operating point en la escala headline del paper, y cómo escala a $N = 20\,000$?”

La grilla de 9 configs barre $\{16, 128, 384\} \dim \times \{500, 2\,000, 10\,000\} N$ para caracterizar la forma del envelope. La grilla de 4 configs fija $\dim = 384$ y barre $N \in \{200, 1\,000, 5\,000, 20\,000\}$ así que el operating point reportado en T11 ($N = 20\,000$) está en la misma grilla que el N-sweep de la familia SQLite en T12–T14. Ambas grillas corren $k = 10$ nearest neighbours, distancia coseno, recall floor $\text{recall}@10 \geq 0.95$, p50 / p95 / p99 sobre 100 queries por celda en estado estable warm (descartando cold cache).

Configuraciones:

- **Dazzle HNSW (float32)**: $M=32$, `efConstruction=400`, `efRuntime` variado en $\{10, 50, 100, 200\}$.
- **Dazzle SQ8 (int8 + NEON SDOT)**: mismos build params HNSW, más cuantización scalar en el path de storage con NEON dot-product en el path de comparación.
- **ObjectBox 4.x**: HNSW vía la anotación `@HnswIndex`, configurada con los mismos $M=32$, `efConstruction=400`, distancia coseno, vectores float32.
- **SQLiteAI 0.9.95**: `vector_init` con `FLOAT32` + coseno, `vector_quantize(max_memory=50MB)` para construir el snapshot int8, `vector_quantize_preload` para warmear el cache, queries a través de `vector_quantize_scan` (linear scan sobre vectores cuantizados).

5.8.2 5.8.2 Tabla de operating-point

Tabla 11 — Comparación de operating point por motor vectorial en dim = 384, N = 20 000, k = 10, recall@10 floor ≥ 0.95 (p50 search latency en μs , ingest total en ms, DB size en disco para motores de la familia SQLite, INFO memory $\rightarrow$ used_memory_dataset para las filas in-memory Dazzle/Valkey).

Engine / Variant	Algorithm	Precision	Recall@10	p50 search ‡	Ingest (ms)	RAM / DB size
Dazzle SQ8	HNSW + int8 SDOT	int8	0.959	208 μs [203, 212]	16 614	9.77 MB †
Dazzle SQ8+Rerank	HNSW + int8 + fp32	int8/fp32	0.982	330 μs	14 966	39.06 MB †
Dazzle F16	HNSW + fp16	fp16	0.984	297 μs	26 082	17.09 MB †
Dazzle HNSW	HNSW	float32	0.952	343 μs	43 028	31.74 MB †
ObjectBox 4.x	HNSW	float32	0.994	853 μs [853, 1078]	387 405	not reported by runner
sqlite_plain	linear scan	float32	1.000	707 302 μs	1 614	79.45 MB
sqlite_vec_default	linear scan	float32	1.000	27 391 μs	1 316	31.00 MB
sqlite_vec_optimized	linear scan	float32	1.000	28 575 μs	869	31.00 MB
sqlite_vec_precompute	linear scan	float32	1.000	26 505 μs	870	31.00 MB
SQLiteAI default *	quantized linear scan	int8	0.987	3 087 μs	723	46.65 MB
SQLiteAI optimized *	quantized linear scan	int8	0.987	2 842 μs	685	46.65 MB
SQLiteAI precompute *	quantized linear scan	int8	0.987	1 407 μs	708	46.65 MB

‡ El intervalo [lo, hi] entre corchetes al lado de las dos celdas headline de la misma clase (Dazzle SQ8, ObjectBox 4.x — ambos HNSW) es un **CI 95 % bootstrap percentile-method cross-run sobre el estadístico p50** [efronbootstrap; @davisinhinkley] computado sobre los cuatro runs independientes post-fix Moto G35 5G archivados en research/benchmarks/results/Moto_G35_5G/vector/ (timestamps 2026-04-28T05:05Z / 05:21Z / 09:24Z / 09:39Z; B = 10 000, seed = 42; script research/scripts/bootstrap_vecbench_cross_run.py; full report en research/paper/vecbench_cross_run_ci.md).

* Las tres filas SQLiteAI son **single-shot del run cross-engine** (el mismo paper384_scale pass que produjo cada otra fila en esta tabla). El sweep dedicado de la familia SQLite de 3 rondas en el mismo N = 20 000 reporta default 9 812 $\pm$ 363 μs , optimized 9 570 $\pm$ 548 μs , precompute 3 072 $\pm$ 4 μs (companion report §2, Tabla 2). Mantenemos el número cross-engine aquí para que cada fila de la Tabla 11 esté en el mismo contexto de medición.

† Las filas Dazzle/Valkey corren in-process y el bench no ejerció un path de persistencia en disco (BGSAVE estaba deshabilitado para mantener el costo de I/O fuera de la medición). Para poner las filas Dazzle en la misma columna que los números db_file_bytes de la familia SQLite, reportamos el **footprint analítico de RAM/disk** en su lugar, computado como $(N \times \text{dim} \times \text{bytes_per_component}) + (N \times M \times 4)$ — los vectores más el grafo HNSW (listas de vecinos int32, M = 32 por nodo).

El head-to-head justo es Dazzle vs ObjectBox: ambos motores corren HNSW.

A recall floor ≥ 0.95 (el operating point común de mobile RAG), Dazzle SQ8 alcanza 208 μs p50 search en N = 20 000 contra ObjectBox 4.x en 853 μs — 4.1× más rápido, ambos sobre HNSW. A recall estricto ≥ 0.99 la imagen se invierte en el eje de recall: ObjectBox mantiene un recall más alto (0.994 vs 0.959 para Dazzle SQ8 en $ef = 10$) y Dazzle SQ8 se ubica en un operating point de recall menor en esta configuración. Eso es un trade-off esperado entre la cuantización int8 que Dazzle SQ8 usa y la precisión float32 que ObjectBox mantiene, no una contradicción.

SQLiteAI sigue siendo una referencia secundaria útil porque es el path SQLite production en muchos stacks móviles. El ratio observado contra SQLiteAI en N = 20 000 es consistente con comportamiento $O(\log N)$ vs $O(N)$ y debe leerse con esa nota algorítmica adjunta.

5.8.3 5.8.3 Interpretación del envelope

A lo largo de la grilla de 9 configuraciones, Dazzle se mantiene en el envelope de search sub-milisegundo para el rango móvil objetivo y ObjectBox permanece en el mismo orden de magnitud bajo settings HNSW alineados. La conclusión de ingeniería relevante es que ambos sistemas son elecciones HNSW-class viables para RAG on-device, con distintos trade-offs de constante-factor según el operating point y el target de recall.

Versiones futuras de SQLiteAI sqlite-vector se espera que expongan HNSW. En ese punto la comparación significativa se desplazará de asimetría de clase algorítmica a análisis de constante-factor entre dos implementaciones HNSW.

5.8.4 5.8.4 Sweep de variantes de extensión SQLite — resumen

Disclosure de clase algorítmica. Esta subsección compara Dazzle SQ8 (HNSW, search $O(\log N)$ esperada) contra SQLiteAI sqlite-vector v0.9.95 (linear scan cuantizado acelerado por SIMD, $O(N)$).

Los dos sistemas están en **clases algorítmicas distintas**, no en la misma clase con constantes diferentes. Los ratios numéricos reportados abajo son por tanto *referencias de envelope* — describen qué tan adentro o afuera del envelope de search sub-milisegundo aterriza cada path en un operating point mobile-RAG representativo — y **no claims de calidad de motor** sobre SQLiteAI como producto.

Para cerrar el gap del “single SQLite path” corrimos un N-sweep focalizado en Moto G35 5G sobre backends vectoriales solo de la familia SQLite — `sqlite_plain`, `sqlite_vec` y SQLiteAI en sus variantes `default` / `optimized` / `precompute` — en $\text{dim} = 384$, $k = 10$, 100 queries, 3 rondas, $N \in \{200, 1\text{ k}, 5\text{ k}, 10\text{ k}, 20\text{ k}\}$. La fila de operating-point $N = 20\,000$ para cada variante está mergeada en la Tabla 11 arriba.

La lectura es **sobre membresía del envelope, no una declaración de ganador**. En $N = 20\,000$, $\text{dim} = 384$, $k = 10$, $\text{recall} \geq 0.95$:

- **Dazzle SQ8** aterriza en $208\ \mu\text{s}$ (Tabla 11) — claramente dentro del envelope de search sub-milisegundo.
- `sqlite_vector_ai_precompute` aterriza en **1 407 μs** en el cross-engine single-shot (Tabla 11) y en **3 072 $\pm 4\ \mu\text{s}$** medio a través del sweep dedicado de 3 rondas — fuera del envelope sub-milisegundo, en milisegundos de un solo dígito.
- `sqlite_vec` (linear scan brute-force) está consistentemente por encima de ambas lecturas SQLiteAI.

El factor $6.8\times\text{--}14.8\times$ entre Dazzle SQ8 y SQLiteAI precompute en este N es por tanto *evidencia de que el path HNSW se mantiene dentro del envelope sub-milisegundo mientras que el path linear-scan cruza al rango de los milisegundos* — i.e., documenta un threshold de tamaño de corpus más allá del cual la elección del motor empieza a importar al nivel del agent-loop.

5.9 Aplicación end-to-end en Moto G35 5G: small-model + RAG on-device

Alcance de esta sección. La ablación RAG end-to-end reportada abajo se corrió originalmente sobre un solo dispositivo físico (Motorola Moto G35 5G, Unisoc T760, cluster A76 ARMv8.2). §5.9.5 extiende el run a un segundo SoC Android físico (Motorola Moto G30, Qualcomm Snapdragon 662, cluster A73 ARMv8.0) y reproduce la 2×2 con CIs 95 % superpuestos en cada celda — tres de las cuatro celdas son bit-idénticas (Q4_K_M + greedy decoding + retrieval idéntico determinizan el token stream) y la cuarta difiere por 0.005 en el punto estimado. La cobertura end-to-end en iPhone 12 Pro queda como trabajo futuro; la validación storage-path en iPhone 12 Pro ya aparece en §5.5.

La tesis de esta sección es a nivel de aplicación: la disponibilidad de una primitiva vectorial in-process habilita un patrón de agente cualitativamente distinto — small-model + RAG on-device [[@lewisrag](#); [@karpukhindpr](#)] — que puede alcanzar accuracy factual mayor que un modelo más grande sin retrieval. La pipeline completa corre on-device, sin cloud y sin servidor externo, incluido en un teléfono Android de \$150. El corpus de 2 K passages que indexamos también mantiene cada passage retrieved bien dentro de la ventana de contexto del small-model, así que los artefactos de precisión-de-retrieval causados por degradación de contexto-largo [[@liulostmiddle](#)] no están en el path entre el índice y la respuesta.

5.9.1 5.9.1 Setup

Indexamos 2 000 passages de un mini-slice determinista de Natural Questions [[@nq2019](#)] en un Motorola Moto G35 5G (Unisoc T760, 4 GB RAM, Android 14). Los passages y los pares (question, gold-passage) vienen del split SBERT pair de NQ [[@sbertnq](#)]; los alias de short-answer canónicos se joinan desde `nq_open` [[@nqopen](#); [@lecorqa](#)] por texto de pregunta lowercased.

Precondición de alias. No cada NQ question tiene short-answer canónico en `nq_open` — el join produce un campo `short_answers` solo para el subset de questions que los autores de NQ-open anotaron. Pre-filtramos el pool de candidatos para mantener solo questions con al menos un short-answer alias, después sampleamos 200 de esos (así cada query en el bench tiene un set de ground-truth no-vacío para `EM_short` / `F1_short`). Los 2 000 passages se construyen como los 200 gold positivos más 1 800 distractors random sacados del mismo pool, seed 42; los passages se truncan a 1 800 caracteres para caber en el contexto de 512 tokens de `bge-small-en-v1.5`. El slice es regenerable desde `research/scripts/nq_slice.py` y está fingerprinted por el prefijo `sha256 63be4b8894c71ff3` (provenance completa en `research/data/nq_slice/README.md`).

Embeddings producidos con `bge-small-en-v1.5` [[@bgesmall](#)] (`q4_k_m`, 24 MB, $\text{dim} = 384$, $n_{\text{ctx}} = 512$); índice Dazzle HNSW_SQ8 con $M=32$, $\text{efC}=400$. Para cada uno de los 200 queries hacemos retrieve de los $k=5$ passages más cosinesimilares con `efRuntime=64` y los inyectamos en el prompt. Configuraciones:

- **Qwen 2.5 0.5B Instruct + Dazzle RAG.** GGUF q4_k_m, 380 MB en disco. n_ctx=2 048. Prompt formado como <system>... <retrieved passages>... <user question>. Decoding greedy, max_new_tokens=64.
- **Qwen 2.5 1.5B Instruct sin RAG.** GGUF q4_k_m, 940 MB en disco — 2.5× más grande, 3× más parámetros. n_ctx=2 048. Prompt formado como <system> <user question>. Decoding greedy, max_new_tokens=64.

Protocolo de evaluación. Para cada query el modelo genera hasta 64 tokens. Extraemos el span de respuesta predicho y_pred como el prefijo de la generación hasta la primera newline o eco fresco Question: / Answer:. Tanto y_pred como el short-answer gold y_gold se normalizan siguiendo el protocolo SQuAD v1.1 [@squad] (lowercasing, removal de los artículos {a, an, the} y puntuación, collapsing de whitespace).

Reportamos tres métricas de short-answer más un backup de passage:

- **EM_short** (estricto) — 1 iff norm(y_pred) == norm(y_gold) para cualquier alias, 0 en otro caso.
- **F1_short** — F1 a nivel token (whitespace tokenisation) entre norm(y_pred) y el alias norm(y_gold) que mejor matchea, promediado sobre queries.
- **EM_contains** (laxo) — 1 iff los tokens normalizados de cualquier alias aparecen como substring contiguo en alguna parte de la generación completa. Esto separa “el modelo sabe la respuesta” de “el modelo responde concisamente”.
- **F1_passage** — token-F1 entre y_pred (whitespace tokens, sin normalización agresiva) y el passage gold completo; mide si la generación reproduce el contexto de soporte.

5.9.2 5.9.2 Resultado — matriz 2×2 completa

Tabla 15 — Accuracy factual end-to-end RAG sobre 200 queries NQ (Moto G35 5G; decoding greedy, max_new_tokens = 64; mismo bench run para las cuatro celdas; raw JSON en research/benchmarks/results/Moto_G35_5G/rag_2x2/rag_e2e_moto_g35_5G_1777395311213.json, SHA-256 00d21f6c8752ffaa1015624b69a5e5d0fd403670d72561e3838bdac0ab461e76).

Cada celda se reporta como point estimate con el CI 95 % bootstrap percentile-method [lo, hi] sobre la array per-query de la métrica (n = 200, B = 10 000, seed = 42). El report bootstrap completo (CIs por celda, ratio CIs paired-qid sobre las 16 celdas métrica × ratio, flags de significancia) vive en research/paper/rag_2x2_with_ci.md y es regenerable desde el mismo JSON vía research/scripts/bootstrap_rag_metrics.py.

Configuración	Tamaño	EM_short	EM_contains	F1_short	F1_passage
Qwen 0.5B (sin RAG)	380 MB	0.015 [0.000, 0.035]	0.105 [0.065, 0.150]	0.079 [0.055, 0.106]	0.151 [0.138, 0.164]
Qwen 0.5B + Dazzle RAG	380 MB	0.120 [0.080, 0.165]	0.630 [0.565, 0.695]	0.235 [0.191, 0.283]	0.334 [0.300, 0.369]
Qwen 1.5B (sin RAG)	940 MB	0.045 [0.020, 0.075]	0.110 [0.070, 0.155]	0.118 [0.084, 0.154]	0.085 [0.073, 0.098]
Qwen 1.5B + Dazzle RAG	940 MB	0.220 [0.170, 0.275]	0.735 [0.670, 0.795]	0.331 [0.282, 0.380]	0.387 [0.355, 0.420]

Leyendo la matriz 2×2 a través de filas y columnas (los CIs de ratios son bootstrap paired-qid; □ marca aquellos cuyo CI 95 % excluye 1.0):

- **Lift por adición de RAG** (mismo modelo, with-RAG vs no-RAG): EM_contains 0.630 vs 0.105 en 0.5B (**6.0× ★**), 0.735 vs 0.110 en 1.5B (**6.7× ★**); EM_short 0.120 vs 0.015 en 0.5B (**8.0× ★**), 0.220 vs 0.045 en 1.5B (**4.9× ★**).
- **El modelo más pequeño con retrieval supera al modelo más grande sin retrieval en cada métrica factual.** 0.5B + RAG vs 1.5B sin RAG: EM_contains 0.630 vs 0.110 (**5.7×**), EM_short 0.120 vs 0.045 (**2.7×**), F1_short 0.235 vs 0.118 (**2.0×**), F1_passage 0.334 vs 0.085 (**3.9×**).

5.9.3 5.9.3 Latency vs accuracy frontier

La capacidad cruda del modelo y el retrieval contribuyen aditivamente. El 1.5B + RAG (0.220 EM_short / 0.735 EM_contains) es el máximo global, pagando un costo de p50 per-turn de 49 s. Para contexto del frontier:

- 0.5B sin RAG: 2.50 s p50 per-turn, 0.015 EM_short.
- 0.5B + RAG: 17.6 s p50 per-turn, 0.120 EM_short.
- 1.5B sin RAG: 2.98 s p50 per-turn, 0.045 EM_short.
- 1.5B + RAG: 49.0 s p50 per-turn, 0.220 EM_short.

El gap dominante de latencia entre filas RAG y no-RAG son los ~5 KB de passages retrieved (k=5, ~1 KB cada uno) que el modelo tiene que prefill en cada turno. En decoding token los runs RAG y no-RAG decodifican aproximadamente

el mismo número de tokens (`max_new_tokens=64`); el delta de latencia es prácticamente todo prefill cost. El path de retrieval-de-storage en sí (HNSW search sobre 2 000 passages) es ~ 0.6 ms en wall clock — invisible en este gráfico.

Lo que importa es que el **patrón RAG está disponible on-device sin dependencia de cloud**; la contribución del backend de storage a ese turn budget es el costo de ~ 22 ms + 0.6 ms embed-and-search — bajo el 0.05 % del row RAG total más rápido.

5.9.4 5.9.5 Extensión cross-platform a tres SoCs Android y un SoC Apple

Para chequear que las conclusiones de §5.9 no son artefactos de un solo chip — ni de un solo OS — re-corrimos la 2×2 completa sobre tres dispositivos adicionales que cubren dos sistemas operativos:

- un Motorola Moto G30 (Qualcomm Snapdragon 662, cluster Cortex-A73, baseline ARMv8.0, 4 GB LPDDR4, Android 11);
- un Huawei P20 Lite ANE-LX3 (HiSilicon Kirin 659, Cortex-A53, baseline ARMv8.0, 4 GB LPDDR4, Android 9.1 / EMUI 9 / kernel 4.9);
- un **Apple iPhone 12 Pro** (Apple A14 Bionic, cores Firestorm + Icestorm, ARMv8.4 + ISA Apple-private, 6 GB unified memory, iOS 26) — la única fila no-Android, ejercitando el port Swift de RagE2EBench en `experiment/llm/ios/` sobre los mismos entry points `C dazzle_llama_*` y `dazzle_vs_*` que el JNI Android usa en las otras tres filas.

Las cuatro filas corrieron con los mismos archivos de modelo, el mismo slice NQ de 2 000 passages (prefijo sha256 63be4b8894c71ff3), y el mismo build de Dazzle (`libdazzle.so` baseline en Android v8.0, `libdazzle_v82.so` en Android v8.2, static `libvalkey-server.a` en iOS — todos derivados del mismo árbol de fuentes `core/platform/dazzle_llama.cpp` + `sdk/android/src/main/cpp/valkeysearch_module.cc`). Greedy decoding, passages retrieved idénticos, token streams idénticos.

Tabla 17 — Reproducción cross-platform §5.9. Medias `F1_short` con CIs 95 % bootstrap-percentile ($B = 10\,000$, $\text{seed} = 42$). Greedy decoding, mismos pesos de modelo, mismo slice NQ. Las ratios con estrella colapsan el par (numerador, denominador) en un único test de significancia contra 1.0 bajo paired-qid resampling. Las filas del Kirin 659 e iPhone 12 Pro corren con `Algorithm.FLAT` en lugar de `HNSW` (sidebar items 6 y 13); el recall de FLAT a esta escala ($N = 2\,000$, $\text{dim} = 384$, $k = 5$) es $> 99\%$, por lo que `F1_short` por celda difiere a lo más ~ 0.005 entre los dos algoritmos — dentro del CI por celda.

Chip	μarch	ISA	RAM	OS	Algo	small no-RAG	small + RAG	large no-RAG	large + RAG
Unisoc T760 (Moto G35 5G)	A76	v8.2	6 GB	Android 14	HNSW	0.079 [0.055, 0.105]	0.235 [0.191, 0.283]	0.118 [0.084, 0.154]	0.487 [0.431, 0.542]
QCOM SD662 (Moto G30)	A73	v8.0	4 GB	Android 11	HNSW	0.079 [0.055, 0.105]	0.240 [0.195, 0.287]	0.118 [0.084, 0.154]	0.487 [0.431, 0.542]
HiSi Kirin 659 (Huawei P20 Lite)	A53	v8.0	4 GB	Android 9	FLAT	0.079 [0.055, 0.105]	0.236 [0.191, 0.283]	0.119 [0.085, 0.155]	0.484 [0.427, 0.539]
Apple A14 (iPhone 12 Pro)	Firestorm	v8.4+	6 GB	iOS 26	FLAT	0.079 [0.055, 0.105]	0.236 [0.191, 0.283]	0.119 [0.085, 0.155]	0.488 [0.432, 0.543]

Los tres chips reproducen las mismas cuatro celdas dentro del CI por celda. Tres de las cuatro celdas (`small no-RAG`, `large no-RAG`, `large + RAG`) son bit-idénticas entre T760 y SD662; la fila del Kirin matchea con ambos a ≤ 0.003 — el delta de recall FLAT vs HNSW y la selección de kernel ggmml v8.0 vs v8.2 contribuyen juntos menos que el half-width del CI con $B = 10\,000$ en cada celda.

La fila del Kirin 659 reporta el run tal como completó sobre el chip después de una **investigación de quince passes** (deadlock de `HNSW addPoint(label = 0)` → fallback a `Algorithm.FLAT`; acumulación del kill-score de `iAware` en EMUI 9 a través del embed loop → driver multi-process de cuatro fases; segfault SIMD del path FLAT del SDK sobre Cortex-A53 → scan brute-force escalar portable sobre un mirror `fp32_store`; deadlock LLM en split-prefill sobre prompt de 570 tokens con `n_batch = 512` → `n_batch = n_ctx`; `iAware` mata el bench process alrededor de la query 30/200 en las variantes Qwen 1.5B → 20 chunks de 10 queries cada uno, un `am_instrument` fresh por chunk,

partials concatenados en el merge — ver `research/results/cross_platform_e2e/ane_lx3_kirin659_investigation.md`). Con los cinco fixes shippeados, la fila del Kirin es **directamente comparable** a los chips HNSW y las ratios son idénticas:

Chip	small + RAG / large no-RAG	small + RAG / small no-RAG	large + RAG / large no-RAG
Unisoc T760	2.00× [1.44, 2.89] □	2.97× [2.05, 4.51] □	4.13× [3.10, 5.86] □
QCOM SD662	2.03× [1.47, 2.95] □	3.03× [2.09, 4.58] □	4.13× [3.10, 5.86] □
HiSi Kirin 659	1.98× [1.43, 2.88] □	2.98× [2.06, 4.54] □	4.07× [3.04, 5.74] □
Apple A14	1.98× [1.43, 2.88] □	2.98× [2.06, 4.54] □	4.10× [3.07, 5.80] □

Los tres enunciados sobre retrieval-como-palanca-dominante (§5.9.4 en versión EN) se sostienen sobre los cuatro SoCs en dos OSe al mismo nivel de significancia. La reproducción también confirma que **las conclusiones de §5.9 son claims sobre el storage engine, no sobre el LLM runtime ni sobre el OS runtime**: los chips difieren $\sim 11\times$ en throughput LLM bruto (p50 de large + RAG: iPhone 12 Pro 30.84 s, T760 49.23 s, SD662 71.99 s, Kirin 659 152.26 s) pero las ratios de F1 que sostienen la tesis de §5.9 son estables. La fila del Kirin también confirma la tesis de storage-engine desde la dirección opuesta: retrieval (scan escalar FLAT @ ~ 2.5 ms p50 para $N = 2\,000$, dim = 384) e ingest (addBatchDirect 47 ms para $N = 2\,000$) operan sobre los presupuestos default del SDK incluso sobre un chip Cortex-A53 / 4 GB del 2017, así que la surface del engine documentada en este paper es portable sobre las tres generaciones de microarquitectura Android testeadas (A76, A73, A53).

Descomposición de latencia. Partir el `total_us p50` por query en sus cuatro componentes del pipeline (embed = forward de BGE sobre la pregunta, search = retrieval vector, prefill = LLM ingiere prompt + passages retrieved, decode = LLM autoregresivo hasta `max_new_tokens = 64`) afina la tesis de storage-engine a un statement de presupuesto:

Tabla 18 — small + RAG descomposición de latencia (mediana por query, ms). Prefill domina, retrieval es < 0.13 % del total en cada chip incluyendo Cortex-A53 del 2017 y Apple A14 del 2020; la ratio prefill $\approx 6\times$ de code que el perfil compute-vs-memory de Qwen 2.5 fija es invariante a través de microarquitecturas y sistemas operativos.

Chip	embed p50	search p50	prefill p50	decode p50	total p50
Apple A14 (iPhone 12 Pro)	14.2	1.7	11 835	2 016	13 576
Unisoc T760	21.5	0.6	15 027	2 924	17 618
QCOM SD662	30.8	0.9	22 237	4 387	26 237
HiSi Kirin 659	67.4	3.7	48 374	9 138	56 159

Dos invariantes visibles sobre los tres chips:

1. **prefill $\approx 6\times$ decode.** El prefill compute-bound (cada token lee el KV cache completo) y el decode memory-bound (cada token streamea una vez) sientan en la misma ratio de FLOPs por token que Qwen 2.5 especifica, sin importar la microarquitectura. T760 es $3.2\times$ más rápido que Kirin en términos absolutos, pero el split intra-query es el mismo.
2. **embed + search □ 1 % de total_us** en cada celda:

Chip	embed	search	prefill	decode	retrieval / total
Apple A14 (iPhone 12 Pro)	0.10 %	0.012 %	87.2 %	14.9 %	0.12 %
Unisoc T760	0.12 %	0.003 %	85.3 %	16.6 %	0.13 %
QCOM SD662	0.12 %	0.004 %	84.8 %	16.7 %	0.12 %
HiSi Kirin 659	0.12 %	0.007 %	86.1 %	16.3 %	0.13 %

La tesis de storage-engine de §5.9 colapsa a un statement de presupuesto, no a un argumento de tuning: una regresión de un orden de magnitud en el path de retrieval (e.g. bajar el recall de HNSW a 80 % o correr FLAT brute-force a $5\times$ los ms que cuesta en Kirin) todavía dejaría el retrieval bajo 1.5 % del total, bien dentro del noise floor del prefill. La spread $3\times$ wall-clock entre chips es 100 % LLM-runtime; el engine documentado en este paper ni ayuda ni perjudica ese envelope.

Techo de recall del retrieval. Una pregunta natural a la descomposición de latencia es si el pipeline de retrieval es el bottleneck del F1 de §5.9. Computar `recall@k` de BGE-small sobre las mismas 200 queries NQ contra el mismo

corpus de 2 000 passages — scoreando “el gold passage de short-answer está en el top-k” contra el campo gold de cada query — da el F1 upper bound que el storage engine *podría* entregar al LLM:

Tabla 19 — recall@k de retrieval de BGE-small sobre el slice de 200 queries NQ. Cosine sobre embeddings unit-normalizados de dim = 384. Un solo número por row porque los embeddings son determinísticos y el chip elegido no cambia el recall — mismo modelo, mismo corpus, mismas queries.

k	recall@k
1	0.905
3	0.970
5	0.980 (<i>paper config</i>)
10	0.990

El pipeline de retrieval entonces entrega el gold passage en el top-5 en 98 % de las queries — pero F1_short aterriza en 0.487 para large + RAG sobre el chip más fuerte. El gap de 49 puntos entre “retrieval perfecto” y “el modelo escribe la respuesta correcta” es **la quality de extraction del LLM, no el recall del storage engine**. El small Qwen 2.5 0.5B compone esto — small + RAG aterriza en 0.236, la mitad del número del large-model, sobre el mismo contexto de 0.98 recall. Un modelo class-7B cerraría la mayor parte del gap remanente sin cambiar una línea del código del engine en este paper; la surface del storage engine satura su upper bound sobre este corpus y ships cero budget bloqueante sobre F1.

Sidebar de ingeniería — fixes de portabilidad shipped durante este sweep cross-platform. Cinco issues SDK-level surgieron al llevar el bench más allá del target original Moto G35 5G. Cada uno está documentado en `research/results/cross_platform_e2e/` y el fix correspondiente se shipped en la rama `kirin-4gb-sdk-opts`:

1. **flash_attn requiere asimdhp.** El path flash-attention de llama.cpp emula conversión $\text{fp16} \leftrightarrow \text{fp32}$ sobre cores sin half-precision nativa (Cortex-A53 / A73 baseline v8.0), lo que hace el path más lento y usa *más* working memory que el kernel estándar. Cambiar el default de `flashAttention` a `CpuFeatures.hasFp16()` en lugar de `true` incondicional mantiene el path lento fuera de chips que no pueden usarlo.
2. **n_batch del embedder capeado bajo n_ctx divide passages largos en prefills multi-batch, lo que deadlockea en cores v8.0 dentro del fallback fp16 de ggml.** El slice NQ de §5.9 tiene al menos un passage de ~450 tokens (passages [21]); el default SDK `n_batch = min(n_ctx, 256)` para el embedder dividía ese prefill en $256 + 194$ sub-batches y se congelaba en Kirin 659 / SD662 v8.0. Subir el default a `n_batch = n_ctx (= 512)` evita el path split en cada passage del slice.
3. **El paralelismo de addBatchDirect bulk no auto-throttle.** El pool default de 8-way `std::thread` deadlockea bajo CPU cgroup throttling agresivo (EMUI iAware), donde el kernel no puede mantener calientes los 8 workers y los threads spinean sobre el mutex per-element de `hnsplib`. Exponer `VectorIndex.setAddBatchThreads(n)` y un env var `DAZZLE_HNSW_BATCH_THREADS` matching permite que un device tight-RAM pin el build pool a un solo worker sin cambiar parámetros del paper.
4. **La importance del foreground-service notification debe ser $\geq \text{HIGH}$ en EMUI 9.** El channel previo `IMPORTANCE_LOW` causaba que el bench process se demote a `WORKINGSET_BACKGROUND` (subCmd 352 de iAware) ~10 s después del foreground grant sin importar wakelock o whitelist de batería; subir la importance del channel y agregar un `re-notify heartbeat` de 4 s es el workaround diagnosticado.
5. **Runs lanzados por activity en EMUI 9 requieren `am start -a MAIN -n` (la forma con `-c LAUNCHER` re-routea via `HwLauncher` y descarta extras del intent).** Runs lanzados por instrumentation pasan por encima del iAware throttling completamente; el harness ahora ships un JUnit entry point `RagE2EBenchTest` invocable via `am instrument`, con la misma surface de extras del intent que la activity lee.
6. **HNSW `addPoint(label = 0)` deadlockea sobre Cortex-A53 + libstdc++ Bionic.** La primera llamada a `hnsplib::HierarchicalNSW::addPoint` bloquea indefinidamente en Kirin 659 / EMUI 9 / kernel 4.9 incluso con un `addBatchDirect` single-thread y un load mínimo de vectores random (4 vecs, `dim = 4`), confirmando que el bug está en la lib, no en el bench. Algoritmo. FLAT (BruteforceSearch) es exacto y termina en 47 ms sobre $N = 2\,000$, `dim = 384` — la fila del Kirin de la Tabla 17 reporta bajo FLAT. La causa raíz del deadlock está documentada en ocho passes de investigación; el SDK va a hacer fallback automático a FLAT sobre chips que matchean el fingerprint en v3.

7. **El kill-score de iAware en EMUI 9 acumula a través del embed loop y dispara sobre el siguiente mmap grande.** Incluso con el workaround FLAT shipped, el bench process es killed en silencio en DazzleLm.open después de un embed loop de 25 min exitoso — sin importar useMmap, useMlock, n_threads o pre-warm. Un probe standalone de instrumentation en un proceso fresh abre el mismo Qwen 0.5B en 1.5 s y exit limpio, confirmando que el kill es el score per-process de iAware, no un límite OS-wide del hardware. El harness ships un driver multi-process de cuatro fases (RagE2EBenchPhases) que parte el bench en invocaciones separadas de am_instrument: phase=embed escribe embeddings a un cache binary, phase=small corre las variantes Qwen 0.5B en un proceso fresh (variant A + variant C back-to-back), y phase=large corre las variantes Qwen 1.5B en otro.
8. **El path FLAT del SDK mal-conectado a través de BruteforceSearch de hnsplib, que segfaultea sobre NEON Cortex-A53.** Con (7) shippeado el bench todavía obtenía 0.025 en small + RAG (vs 0.235 en los chips HNSW) porque RagE2EBenchPhases.ensureServerRunning arrancaba Valkey sin DazzleModule.VectorSearch, así que FT.CREATE no tenía handler y el schema per-index nunca aterrizaba en g_indexes — addBatchDirect / searchDirect JNI-direct retornaban en silencio con 0 hits. Con el módulo cargado, la siguiente capa del bug emergió: el SIMD distance kernel de BruteforceSearch::searchKnn de hnsplib segfaultea sobre loads NEON 16-byte misaligned sobre el stride packed [vec, label] que hnsplib usa, en Cortex-A53 + libstdc++ Bionic. El fix mirrorea cada vector del path FLAT en schema->fp32_store y reemplaza searchKnn con un scan brute-force escalar portable; ~2.5 ms por query sobre N = 2 000, dim = 384 en Cortex-A53. El path HNSW no cambia.
9. **Split-prefill del LLM deadlockea en Cortex-A53 v8.0 cuando el largo del prompt excede n_batch.** Con (7) y (8) shipped, el bench pasaba las fases de embed y addBatch pero el bench process era killed dentro de segundos de la primera query +RAG en DazzleLm.generate. Las variantes no-RAG completaban — distinto code path, prompt de ~30 tokens. El prompt +RAG es de ~570 tokens y cfg.llmNBatch = 512, así que llama.cpp partía el prefill en una primera call de 512 tokens + una continuación de 58 tokens, golpeando el mismo fallback fp16 ggml v8.0 que el item 2 documentó para el embedder. Subir llmNBatch a llmNCTX (= 2048) hace prefill de cualquier prompt hasta el context size en una sola call; las queries +RAG entonces completan con prompt_tokens.avg = 570 matcheando T760 / SD662.
10. **iAware re-dispara después de ~30 queries de Qwen-1.5B + RAG incluso con los items 7-9 aplicados.** La variante D (large + RAG) consistentemente muere entre query 5 y query 30 a través de reboots y reinstalaciones. El harness del bench ahora ships un runner chunked de variantes (runRagE2EVariantChunk con extras q_offset / q_limit) para que cada chunk corra en un proceso am_instrument fresh y los archivos JSON per-chunk sean concatenados por la fase de merge. La fila del Kirin de la Tabla 17 fue producida por 20 chunks de 10 queries para variant D más 4 chunks de 50 queries para variant B; wall clock total para Phase 2b ≈ 8 hr 50 min.
11. **Watchdog de launch iOS (0x8BADF00D) en el primer run de RagE2EBench.** El bench monolítico RagE2EBench.run() invocado inline desde DazzleExperimentApp.init() agota el watchdog de launch de 20 segundos de iOS antes de que SwiftUI tenga chance de renderizar, así que FrontBoard mata el proceso con 0x8BADF00D ProcessVisibility:Foreground. Fix: dispatchear el bench en DispatchQueue.global(qos: .userInitiated).async desde init() para que el main runloop de SwiftUI agende la view placeholder dentro de la ventana del watchdog. El bench termina ~25-35 min después en background queue y se hace exit(0) solo. Mismo fix lands como utility public en el entry point Swift de RagE2EBench.run() así cualquier app iOS que use el entry point obtiene el dispatch automático.
12. **Default n_batch < n_ctx del context LLM en iOS gatilla split prefill en prompts largos.** Con (11) shippeado, el bench iPhone pasaba embed + addBatchDirect pero el proceso era killed dentro de 1 s de la primera query +RAG en llama_decode — mismo pattern que el pass 15 del Kirin documentó para Android v8.0, esta vez en el build de llama.cpp iOS. dazzle_llama_new_context shippeaba con n_batch = 512 hard-coded; el prompt de \$5.9 es ~570 tokens así que llama_decode parte el prefill en 512 + 58 sub-batches y el continuation aborta. Fix: setear n_batch = n_ctx en dazzle_llama_new_context para que cualquier prompt hasta context size hace prefill en una sola llamada llama_decode. El cambio aplica en cada plataforma; cuesta ~30 MB extra de compute buffer a n_ctx = 2048, despreciable vs los pesos del modelo.
13. **Método convenience Swift DazzleServer.vectorIndex(...) sin initialCapacity.** Con (11) y (12) shippeados, el bench pasaba la fase LLM pero addBatchDirect abortaba en el elemento 1024 con BruteforceSearch::addPoint runtime_error("exceeds limit")

de hnsplib porque el index FLAT se creaba con el default SDK `INITIAL_CAP = 1024`. El bench Kotlin Android pasaba 2 000 vía el ctor low-level `vectorIndex(...)` que acepta `initialCapacity`; el método convenience Swift en `DazzleServer.shared.vectorIndex(...)` no lo exponía. Fix: extender la firma `DazzleServer.vectorIndex iOS` con `initialCapacity: Int = 0` (más `m, efConstruction`) para que los callers puedan pre-sizear como en el lado Android.

Los items 1–5 son fixes universales de portabilidad que landed sobre los cuatro chips. Los items 6–10 son específicos del path Kirin 659 y los items 11–13 específicos del port iOS; ninguno cambia la comparación numérica de las celdas de la Tabla 17. Juntos cierran el gap entre “el bench corrió sobre el chip donde lo desarrollamos” y “el bench corre sobre un spread de SoCs Android mid-range y un SoC Apple sobre dos sistemas operativos” — una precondition para cualquier claim cross-platform / cross-OS sobre una superficie de engine embebida.

6 Discusión

6.1 Agregados materializados como primitiva, no como optimización

El retrieval de baja latencia en este paper monta sobre el patrón de agregados materializados, no sobre alguna marca específica de motor de base de datos. Ya sea implementado como un hash mantenido por Lua en Dazzle, una tabla mantenida por triggers en SQLite, o un step explícito de update en una estructura in-memory, el patrón desplaza el trabajo de agregación al write time y hace bounded el retrieval en read time.

La contribución de Dazzle no es inventar este patrón. La contribución es entregarlo como una superficie primitiva first-class (EVALSHA-maintained hash + HMGET) con acceso SDK tipado, así que el autor de la aplicación no necesita construir lógica de migración, orquestación de triggers, o código de mantenimiento manual para cada app.

Esta distinción importa para la tesis del paper: en el envelope de latencia donde todos los backends son aceptables, el factor decisivo es menos “¿puede existir el patrón?” y más “cuánta ceremonia de ingeniería se requiere para hacerlo correcto y mantenible en producción”.

6.2 El bloque de contexto bounded

La propiedad de ~58–62 tokens independiente de N viene de una decisión arquitectónica, no de coincidencia. El bloque de contexto codifica seis escalares agregados (min/max/avg/count/...) más el sumario probabilístico, no una lista de N lecturas crudas. El tamaño del prompt por tanto se desacopla del tamaño del dataset: un agente corriendo durante semanas en un dispositivo no debería consumir progresivamente más de la ventana de contexto del modelo simplemente porque más datos se han acumulado.

6.3 Limitaciones

- **Superficie primitiva contada como API nativa, no como equivalencia expresiva.** La Tabla 1 (§2.2) reporta disponibilidad de primitivas como un check categórico (N API nativa / E extensión oficial / A re-implementación a nivel de aplicación / T extensión third-party) sobre cómo el backend llega a cada construcción, con el conteo headline medido solo sobre N. Las primitivas marcadas E, A o T para backends no-Dazzle son *implementables* atómicamente a través de las facilidades general-purpose del motor subyacente — por ejemplo, range queries de sorted-set vía `ORDER BY + WHERE BETWEEN` en SQLite, increments atómicos de float vía `UPDATE ... SET v = v + ?` dentro de una transacción, indexación geográfica vía la extensión `R*Tree` de SQLite (extensión oficial enviada con la SQLite amalgamation desde 2008), bounded MAXLEN streams vía triggers, y TTL vía un job DELETE programado. La señal de la Tabla 1 es por tanto “cuánto código pegamento escribe el autor del agente para alcanzar esta primitiva” (una cuestión ergonómica de superficie primitiva que ata de vuelta a la Tabla 9), no “esta funcionalidad es alcanzable en este motor”, que en casi cada caso, sí.
- **Post-mortem del harness.** Un bug en la truth-source `SqliteBruteforceVector` causó que data obsoleta se acumulara a través de configuraciones del benchmark recall-floor en v1; fue arreglado en el commit 1e3d5f5 y cada celda de las Tablas 4, 11 y 12 de esta revisión viene del run post-fix. La timeline completa (introducción, detección, fix, asserts que atrapan una regresión futura, y una auditoría de cada otro benchmark on-device en el repo por el mismo bug pattern) está documentada en el Apéndice B (research/paper/appendix_b_harness_postmortem.md).

- Evaluación end-to-end LLM en un solo dispositivo físico (Moto G35 5G) + validación cross-platform en iPhone 12 Pro. Los resultados en otros SoCs y versiones OS pueden diferir; los reportamos en tres familias adicionales de SoC Android (Unisoc, MediaTek, Qualcomm) en companion benchmark reports.
- Carga sintética. Streams reales de IoT tienen patrones bursty, fallos de sensor, y concurrencia adicional que no modelamos.
- La evaluación de accuracy del modelo usa tres estadísticas verificables; una evaluación más rigurosa usaría un set de preguntas factuales más grande y múltiples runs por condición.
- Paridad de transporte iOS/Android incompleta: el SPSC ring buffer y el path `io_uring` son Linux-only; iOS se queda sobre el Phase-0 pipe path, suficiente para la carga evaluada (§5.5).
- **Carga LLM end-to-end de un solo dispositivo.** El bench end-to-end RAG de §5.9 se reporta en un solo dispositivo físico (Moto G35 5G).
- **Los peers comerciales evolucionan.** SQLiteAI v0.9.95 no expone HNSW al cierre de este bench; una versión futura del producto que incluya HNSW desplazaría la comparación de §5.8 de “HNSW vs brute-force scan” a “HNSW vs HNSW”, reduciendo el gap a constant factors en lugar de asimetría algorítmica.
- **Skew de footprint allocator-platform.** El tamaño on-disk e in-memory de un backend embebido es sensible al allocator host y a la configuración default. Observamos un delta cross-platform de 23× sobre Dazzle (153 KB en iOS vs 6.7 KB en Android, mismo Valkey-fork in-process, misma carga de 200 lecturas) atribuible al `libsystem_malloc` de Apple versus el comportamiento de la arena `jemalloc` de Android, y un delta de 42× sobre RocksDB en la dirección opuesta (4.41 MB Android vs 104 KB iOS) impulsado por los defaults de pre-allocation WAL + SST de Android.
- **Comparación de configuración default en §5.2.** La comparación storage-latency usa configuraciones de backend default. Un setup SQLite con vistas materializadas mantenidas manualmente vía triggers cerraría la mayor parte del gap medido. La contribución de Dazzle es shipear el patrón nativamente, no claimar superioridad algorítmica sobre SQLite.
- **El benchmark vectorial abarca dos clases algorítmicas.** En §5.8, Dazzle y ObjectBox corren HNSW ($O(\log N)$), mientras que SQLiteAI v0.9.95 expone brute-force quantized scan ($O(N)$). Una release futura de SQLiteAI con HNSW user-accessible desplazaría la comparación a constant factors.
- **El benchmark de aplicación RAG aísla disponibilidad de retrieval, no identidad de motor vectorial.** La sección §5.9 compara with-retrieval vs without-retrieval y no aísla el motor vectorial de Dazzle contra ObjectBox o SQLiteAI en la misma pipeline end-to-end.
- **Sesgo de autor sobre la medición LOC.** El autor de este paper es también el autor de las seis implementaciones de backend contra las que Dazzle se mide en la Tabla 9. Los managers Dazzle-side fueron los primeros escritos y los más iterados; los managers SQLite/LMDB/RocksDB/ObjectBox son ports directos de la misma superficie de capa de estado del agente pero no fueron optimizados subsecuentemente por line count.
- **Conflicto de interés y compromiso público.** El autor de este paper es también el autor de `dazzle-sdk` (Apache-2.0; Maven Central / pub.dev / npm / Swift Package Manager) y de cada wrapper de comparison-engine benchmarkado aquí. Para hacer la comparación falsificable en lugar de auto-servida, tres compromisos concretos sostienen desde la fecha de esta revisión en adelante:
 1. **Los seis wrappers de backend son artefactos first-class en el repositorio.** Todo su source, build configuration, y test entry points viven bajo `experiment/backends/` y tienen la misma licencia Apache-2.0 que Dazzle. Cualquiera puede forkear, re-tunear, y re-correr.
 2. **External pull requests que reduzcan el LOC count de cualquier wrapper no-Dazzle, o que mejoren cualquier número medido del backend no-Dazzle en las Tablas 3 / 5 / 11, serán revisados y mergeados sobre mérito técnico.**
 3. **Cada optimización aceptada se registra en `experiment/backends/CHANGELOG.md` antes del próximo bench freeze.**

La metodología del benchmark, los outputs JSON crudos, y los scripts de análisis están abiertos en el repositorio (paths listados en §8.1 Reproducibility) así que cualquier claim en el paper puede re-correrse contra un build independiente de los motores de comparación.

6.3.1 Validación cross-platform del benchmark vectorial

Las Tablas 11 y 12 se reportan en un solo dispositivo físico (Moto G35 5G, Unisoc T760, ARMv8.2-A). Para descartar artefactos single-device, re-corrimos el mismo harness sobre tres familias adicionales de SoC Android y re-

bootstrapeamos la celda headline $N = 20\,000$ con paired-query resampling ($B = 10\,000$, seed = 42). Las tablas per-engine completas están en `research/paper/vecbench_cross_platform_ci.md`; los headline ratios se reproducen aquí:

Device	SoC (ISA, big core)	Round 1 p50 (dispatched)	Round 2 p50 (baseline-forced) Δ
Moto G35 5G (<i>reference</i>)	Unisoc T760 (ARMv8.2-A + fp16/dot, Cortex-A76)	269 [261, 273] μ s	269 [264, 273] μ s 0 μs
Huawei Y9a (FRL-L23)	MediaTek Helio G80 (ARMv8.2-A + fp16/dot, A75)	671 [642, 701] μ s	588 [566, 612] μ s -83 μs ²
Moto G30	Snapdragon 662 (ARMv8.0-A, Cortex-A73)	445 [409, 478] μ s	519 [488, 548] μ s +74 μ s ¹
Huawei P20 Lite (ANE-LX3)	Kirin 659 (ARMv8.0-A, Linux 4.9, Cortex-A53)	1054 [1035, 1092] μ s	1043 [1014, 1078] μ s -11 μ s ¹

¹ Los chips ARMv8.0 corren la misma `libdazzle.so` baseline en ambas rondas (la variante v82 haría SIGILL); el Δ ronda-a-ronda es por tanto puro ruido térmico/load, ranging $\pm 10\%$ en $N = 20\,000$.

² En Helio G80 (Cortex-A75 [`@armcortexa75`] big core) el binario v82 dispatched es **más lento** que el baseline en $\approx 12\%$ en p50 (los CI 95 % no se solapan: [642, 701] vs [566, 612] μ s). Los kernels NEON del hot-path son idénticos — `simsimd` runtime-selecciona los mismos símbolos `_neon_f16` / `_neon_dotprod` en ambos binarios — así que el gap está en el código C++ circundante.

6.4 Asimetría algorítmica en el benchmark vectorial

La comparación en §5.8 abarca dos clases algorítmicas: HNSW (Dazzle, ObjectBox) es approximate nearest neighbour search con expected $O(\log N)$ search complexity [`@hnsw`]; SQLiteAI v0.9.95 implementa linear scan acelerado por SIMD $O(N)$ sobre vectores cuantizados int8. La asimetría es por diseño del producto SQLiteAI — `vector_quantize_scan` es el único query path optimizado que el producto expone; HNSW no es user-accessible en esta versión.

Dentro de la Tabla 11 la lectura de operating-point es la que se debe usar: **Dazzle SQ8 aterriza en recall = 0.959 / p50 = 208 μ s, ObjectBox 4.x en recall = 0.994 / p50 = 853 μ s, SQLiteAI precompute en recall = 0.987 / p50 = 1 407 μ s**, todos en $N = 20\,000$, dim = 384, recall floor ≥ 0.95 .

Los dos motores HNSW (Dazzle SQ8 y ObjectBox) son **dos puntos sobre la misma curva Pareto recall-latency**, no winner / loser: Dazzle SQ8 trades precisión de cuantización int8 por p50 $\sim 4\times$ menor; ObjectBox mantiene precisión fp32 y paga el costo de latencia. **Ambas elecciones se mantienen dentro del envelope LLM-noise-floor en este N**. SQLiteAI se ubica en una clase algorítmica distinta ($O(N)$ scan); su celda 1 407 μ s todavía cabe en el noise floor en $N = 20\,000$ pero no en $N \gg 20\,000$ — el threshold de tamaño de corpus que §5.8.4 documenta.

7 Trabajo relacionado

Inferencia on-device. LiteRT-LM, llama.cpp, MLC-LLM, y ExecuTorch [`@litertlm`; `@llamacpp`; `@mlcmlm`; `@executorch`] apuntan a compresión de modelo y eficiencia de runtime. Ninguno aborda la capa de ejecución stateful; cada inference call se trata como un evento independiente.

Memoria para agentes. MemGPT [`@memgpt`] propone una jerarquía de memoria de dos niveles (in-context + external) targeting server deployment. Generative Agents [`@generativeagents`] usa un memory stream retrieval-augmented para simulación NPC. A-MEM [`@amem`] introduce memoria agent-managed con linking dinámico. Las tres asumen entornos cloud o server con un proceso de base de datos separado, red, y RAM substancial. Dazzle mueve esa capa de memoria externa **dentro del proceso de la app móvil**.

Redis sobre hardware restringido. Redis sobre Raspberry Pi alcanza latencia sub-milisegundo pero corre como demonio separado sobre TCP. No conocemos un Valkey-on-Android port publicado.

Motores embebidos. SQLite, LMDB, y RocksDB están diseñados desde cero como librerías in-process. Dazzle toma el path opuesto: arranca de un motor server diseñado alrededor de TCP loopback y un event loop single-threaded, y reescribe su subtrato de I/O (no sus estructuras de datos) para hacer ejecución in-process el default. El resultado se sienta entre ambos campos. La biblioteca se consume exactamente como un motor embebido, mientras que el modelo de datos es el que un full server-grade database expone.

Bases de datos vectoriales móviles — tres productos distintos. El ecosistema mobile SQLite-vector incluye tres productos comúnmente confundidos que vale la pena distinguir aquí. (1) **SQLite** plano no tiene soporte nativo para vectores y se benchmarkea solo sobre su capa de storage en §5.2. (2) El **sqlite-vec** open-source de Alex Garcia (g

ithub.com/asg017/sqlite-vec, Apache 2.0) es una extensión SQLite agregando vector search brute-force; esta revisión lo benchmarkea en el sweep SQLite-family (§5.8.4). (3) **SQLiteAI sqlite-vector** [sqliteai/vector] (github.com/sqliteai/sqlite-vector, Elastic Licence 2.0) es el producto comercial de SQLite Cloud, Inc. (la entidad corporativa detrás del ecosistema SQLite AI); ship un path de query linear-scan cuantizado acelerado por SIMD (vector_quantize_scan) y deliberadamente evita HNSW. **ObjectBox 4.x** [objectbox4] es el otro peer comercial en nuestro benchmark y ship HNSW nativo respaldado por vectores float32.

Librerías ANN vectoriales server-grade. **FAISS** [faiss] (Facebook AI), **DiskANN** [diskann] (Microsoft Research), y **Milvus** [milvus] (Zilliz) fijan el baseline open-source para approximate nearest-neighbour search a escala billion-point sobre hardware server. La literatura de cuantización vectorial debajo de esos motores — Product Quantisation [jegoupq] en particular — es el precedente algorítmico para el path SQ8 que Dazzle usa.

Los kernels NEON de Dazzle para fp32 dot product, fp32 L2-squared, fp16 dot product, e i8 cosine vienen de `simsimd` [simsimd] (Vardanian, Apache 2.0 license) y usan el runtime dispatcher de esa librería (`simsimd_capabilities()` sobre `/proc/cpuinfo`) para seleccionar la mejor variante disponible en cada chip.

Object stores móviles más allá de SQLite. **Realm** [realm] (ahora MongoDB) y **WCDB** [wcdb] (Tencent / WeChat) son los dos peers production-deployed de ObjectBox en el espacio móvil object-store. Ambos targetean Android + iOS, ambos ship APIs typed más altas que SQLite raw, y ambos son ampliamente usados en apps comerciales. Ninguno ofrece vector search o HyperLogLog como primitiva (Realm ship full-text search; WCDB es SQLite-on-the-wire underneath).

Evaluación de RAG. **RAGTruth** [ragtruth] es el corpus canónico de hallucination para evaluación retrieval-augmented LLM al cierre de 2024. La sección §5.9 usa NQ-open en su lugar porque la unidad de medición aquí es *recall de canonical short-answer strings* (si el LLM emite el gold span cuando retrieval está presente). RAGTruth mide hallucination *dado* contexto retrieved, que es una señal estrictamente downstream que requiere un hallucination judge. Layerar evaluación estilo RAGTruth sobre el setup de §5.9 es trabajo futuro; pertenecería al mismo eje que el reporting EM-vs-F1 que ya incluimos.

8 Conclusión

Dazzle propone una lente diferente de selección de backend para agentes on-device. La superficie primitiva, la ergonomía de desarrollador, y el envelope de latencia importan más que carreras aisladas en microsegundos. En la carga medida cada backend evaluado opera dentro de un envelope aceptable de retrieval; los diferenciadores operativos son qué primitivas de agent-state están disponibles nativamente y cuánto esfuerzo de ingeniería cuestan de usar.

Tres resultados empíricos respaldan ese framing. La latencia de retrieval en el path de estado estable de Dazzle es aproximadamente 0.00176 % de un solo turno de inferencia LLM on-device (50 μ s contra ~ 2.84 s para Gemma 4 E2B en el Moto G35 5G), lo que ubica el costo de retrieval del backend dentro del piso de ruido del bucle end-to-end. Superficie primitiva y esfuerzo de desarrollo difieren materialmente: Dazzle expone diez primitivas nativas contra ≤ 4 en las alternativas embebidas medidas, con implementaciones representativas de agent-state aterrizando alrededor de 175 LOC (Android) / 186 LOC (iOS) en Dazzle contra aproximadamente 200–290 LOC a través de las alternativas (Tabla 9, ambas plataformas). A nivel de aplicación, una ablación 2×2 RAG eleva `EM_contains` 6.0× sobre Qwen 2.5 0.5B (0.105 $\rightarrow$ 0.630) y 6.7× sobre Qwen 2.5 1.5B (0.110 $\rightarrow$ 0.735); un modelo de 380 MB con retrieval supera a un modelo 3× más grande sin retrieval en cada métrica factual, end-to-end en un dispositivo Android de \$150.

La pregunta práctica para el próximo deployment on-device por tanto se desplaza de “¿qué backend es más rápido?” a “¿qué set de primitivas y qué composición de modelo encajan mejor en la aplicación, dado que el costo de retrieval es efectivamente invisible al nivel de turno?”.

Dazzle se distribuye públicamente como `dazzle-sdk 1.0.0-beta.4` sobre Maven Central, pub.dev, npm, y Swift Package Manager. El código original de Dazzle se publica bajo Apache-2.0; las porciones derivadas de Valkey retienen BSD-3-Clause. Invitamos a la comunidad a validar estos resultados sobre hardware móvil adicional y a extender la matriz del benchmark a través de cargas más amplias.

8.1 Artefacto y reproducibilidad

Para hacer la evaluación auditable, este repositorio incluye los scripts, dataset builders, y árboles de resultados crudos usados para producir las tablas del paper. Los componentes están organizados así:

- **Bench runners:** `research/scripts/run_experiment.sh`, `run_full_benchmark.sh`, `run_ios_benchmark.sh`, `run_ablation_sweep.sh`, `run_storage_microbench_per_backend.sh`, `run_vector_sqlite_family.sh`.
- **Generación de dataset y RAG slice tooling:** `research/scripts/generate_dataset.py`, `nq_slice.py`, `recompute_rag_metrics.py`.
- **Análisis de resultados y generación de tablas:** `analyze_results.py`, `analyze_storage_microbench.py`, `make_vector_bench_table.py`, `analyze_vector_sqlite_family.py`.
- **Árboles de resultados crudos y procesados:** `research/benchmarks/results/`, `research/results/`.

Cada métrica headline en §5 fue computada desde estos artefactos locales. Una guía compacta paso-a-paso de reproducción se provee en `research/paper/REPRODUCIBILITY.md` y puede ejecutarse end-to-end sobre el mismo workspace layout.

8.2 Política de versionado y compromiso público de actualización

Este paper documenta un moving target: `dazzle-sdk` es un artefacto vivo bajo desarrollo activo a través de cuatro registries de paquetes, los backends de comparación evolucionan, y varios hallazgos en esta revisión son explícitamente null results que invitan a investigación adicional. Para mantener al paper como una referencia útil en lugar de un snapshot congelado, el autor se compromete a la siguiente política de versionado en arXiv:

1. **Cada cambio medible en cualquier celda headline de las Tablas 3, 5, 11, 12, o 15 produce una nueva revisión arXiv.**
2. **Cada nuevo dispositivo físico agregado a la tabla cross-platform (§6.3) produce una nueva revisión arXiv.**
3. **Cada PR externo aceptado que mejore los números medidos de un backend no-Dazzle produce una nueva revisión arXiv** — con el PR contribuyente citado y los números viejos preservados con strikethrough.
4. **El abstract arXiv lleva una fecha de “Last updated” y un changelog de una línea del cambio material más reciente.**
5. **Todas las mediciones JSON crudas** viven en `research/benchmarks/results/` bajo paths timestamped, nunca sobrescritas a través de revisiones. Las re-derivaciones bootstrap-CI son deterministas ($B = 10\ 000$, $seed = 42$).
6. **El branch main del repositorio es el source of truth.** Cuando una discrepancia surja entre una revisión arXiv y main, main gana; la discrepancia gatilla una revisión por (1).

El autor es alcanzable en `ivan.aliaga@urp.edu.pe` para preguntas de revisor, issues de reproducción, y pull requests contra el código del benchmark. Issues abiertos en el repositorio GitHub se acknowledgean dentro de siete días; las revisiones arXiv numeradas se procesan dentro de catorce días del trigger event.

9 Referencias

Ver `research/paper/arxiv-build/refs.bib` para las entradas bibliográficas completas. Esta versión en español preserva las citas verbatim del paper en inglés (formato `[@key]` por entrada bibtex). 49 referencias numeradas.

10 Apéndice A — Capa de adaptadores LLM (referencia)

El SDK Dazzle expone una sola interfaz `LLMClient` (completion, streaming, deltas de tool-call, lifecycle) y ship cinco adaptadores concretos detrás de ella:

- **LlamaCppClient** — adaptador local llama.cpp, GGUF q4_k_m / q5_k_m / q8_0, n_ctx configurable.
- **LiteRtLmClient** — adaptador LiteRT-LM (Google AI Edge), artefactos `.litemlm` cargados via runtime LiteRT.
- **FoundationModelsClient** — adaptador Apple Intelligence (iOS 26+), enruta a Apple’s on-device foundation model bridge.
- **OpenAICompatibleClient** — adaptador HTTP-compatible para llamar a APIs OpenAI-style (tanto endpoints OpenAI como servidores compatibles).
- **AnthropicClient** — adaptador para Anthropic Messages API `[@anthropicapi]`.

Las cinco implementaciones residen en `sdk/android/src/main/java/dev/dazzle/sdk/edge/` (Kotlin) y `sdk/ios/Sources-LiteRTLM/`, `sdk/ios/Sources-FoundationModels/` etc. (Swift), comparten la misma interfaz tipada

de `completion(prompt, params) / streamCompletion(prompt, params, onDelta)`, y son intercambiables desde el agent-loop perspective.

Referencias